

# Einführung in die Datenanalyse mit R (700104)

Kursskript



Dr. Johannes SIGNER  
Abteilung Wildtierwissenschaften  
Büsgenweg 3  
37077 Göttingen

[jsigner@uni-goettingen.de](mailto:jsigner@uni-goettingen.de)

Dr. Kai HUSMANN  
Abteilung Forstökonomie und nachhaltige Landnutzungsplanung  
Büsgenweg 1  
37077 Göttingen

[kai.husmann@uni-goettingen.de](mailto:kai.husmann@uni-goettingen.de)



Fakultät für Forstwissenschaften und Waldökologie  
Georg-August-Universität Göttingen



Wintersemester 2023/2024

---

<sup>13</sup> Dieses Werk ist lizenziert unter einer [Creative Commons Namensnennung - Nicht-kommerziell - Weitergabe](#)  
<sup>14</sup> [unter gleichen Bedingungen 4.0 International Lizenz](#).

<sup>15</sup> Zitiervorschlag:  
<sup>16</sup> Signer, J. und Husmann, K. (2021) Skript zur Vorlesung Einführung in die Datenanalyse mit R, Georg-  
<sup>17</sup> August-Universität Göttingen.

<sup>18</sup> Letzte Aktualisierung: 12. Oktober 2023

---

## 19 Vorwort und Danksagung

20  
21 Lernziel des Kurses ist die Einführung in die Arbeit, Visualisierung und Analyse von (forstlichen) Datensätzen  
22 mit dem Statistikprogramm *R*. Der Schwerpunkt liegt dabei auf der Datenanalyse (Data Science). Statistische  
23 Methoden werden nur an wenigen Stellen exemplarisch angewendet. Statistische Grundlagen sind nicht Teil  
24 des Kurses. Weitere Materialien werden nicht benötigt. Gelöste Übungsaufgaben werden Ihnen über StudIP  
25 zugänglich gemacht. Dort werden auch ggf. Ankündigungen bekanntgegeben. Um die Credits für den Kurs  
26 zu erhalten, müssen Sie am Ende des Kurses eine mündliche Prüfung ablegen. Für die Prüfung werden  
27 Sie eine der 50 Prüfungsfragen aus diesem Skript zufällig ziehen und vorbereiten. Nach der 15-minütigen  
28 Vorbereitungszeit beträgt die Prüfungszeit weitere 15 Minuten. In der Prüfungszeit präsentieren Sie zunächst  
29 Ihre Lösung und beantworten anschließend vertiefende Fragen zu Ihrer Lösung und zum gesamten Lehrinhalt  
30 des Kurses.

31 Dank für Anmerkungen gilt Markus Benesch, Sofie Biberacher und Josephine Trisl. Teile des Unterkapitels  
32 zu Schleifen und Kontrollstrukturen ist an das R Skript des Kurses Computergestützte Datenanalyse von  
33 Robert Nuske, Nikolas von Lüpke und Joachim Saborowski angelehnt.

# Inhaltsverzeichnis

34	<b>1 R und RStudio</b>	<b>4</b>
35	1.1 Installation von R und RStudio . . . . .	4
36	1.2 Erste Schritte in R . . . . .	4
37	1.3 Kommentare . . . . .	5
38	<b>2 Variablen, Funktionen und Datentypen</b>	<b>7</b>
39	2.1 Variablen beim Programmieren . . . . .	7
40	2.2 Datentypen . . . . .	8
41	2.3 Funktionen . . . . .	9
42	2.4 Datenstrukturen . . . . .	10
43	2.5 Funktionen . . . . .	11
44	<b>3 Vektoren</b>	<b>13</b>
45	3.1 Funktionen zum Arbeiten mit Vektoren . . . . .	15
46	3.2 Statistische Funktionen . . . . .	17
47	3.3 Beispiel Fotofallen . . . . .	17
48	3.4 Arbeiten mit logischen Werten . . . . .	19
49	3.5 Zugreifen auf Elemente eines Vektors (=Untermengen) . . . . .	21
50	3.6 Der %in%-Operator . . . . .	23
51	<b>4 Faktoren (factors)</b>	<b>25</b>
52	<b>5 Spezielle Einträge</b>	<b>28</b>
53	5.1 NA . . . . .	28
54	5.2 NULL . . . . .	29
55	5.3 Inf . . . . .	29
56	<b>6 data.frames oder Tabellen</b>	<b>32</b>
57	6.1 Wichtige Funktionen zum Arbeiten mit data.frames . . . . .	33
58	6.2 Zugreifen auf Elemente eines data.frame . . . . .	34
59	<b>7 Schreiben und lesen von Daten</b>	<b>37</b>
60	7.1 Textdateien . . . . .	37
61		

62	<b>8 Erstellen von Abbildungen</b>	<b>39</b>
63	8.1 Base Plot . . . . .	39
64	8.1.1 Mehrere Panels . . . . .	44
65	8.1.2 Speichern von Abbildungen . . . . .	45
66	8.2 Histogramme . . . . .	46
67	8.3 Boxplots . . . . .	48
68	8.4 ggplot2: Eine Alternative für Abbildungen . . . . .	50
69	8.4.1 Multipanel Abbildungen . . . . .	59
70	8.4.2 Plots kombinieren . . . . .	60
71	8.4.3 Speichern von plots . . . . .	64
72	<b>9 Mit Daten arbeiten</b>	<b>65</b>
73	9.1 dplyr eine Einführung . . . . .	65
74	9.2 Arbeiten mit gruppierten Daten . . . . .	68
75	9.3 pipes oder %>% . . . . .	70
76	9.4 Joins . . . . .	71
77	9.5 ‘long’ and ‘wide’ Datenformate . . . . .	73
78	9.6 Auswählen von Variablen . . . . .	75
79	9.7 Einzelne Beobachtungen abfragen ( <code>slice()</code> ) . . . . .	76
80	9.8 Spalten trennen . . . . .	80
81	<b>10 Arbeiten mit Text</b>	<b>82</b>
82	10.1 Arbeiten mit Text . . . . .	82
83	10.2 Finden von Textmustern . . . . .	84
84	<b>11 Arbeiten mit Zeit</b>	<b>87</b>
85	11.1 Arbeiten mit Zeitintervallen . . . . .	89
86	11.2 Formatieren von Zeit . . . . .	90
87	<b>12 Aufgaben Wiederholen (for-Schleifen)</b>	<b>91</b>
88	12.1 Schleifen . . . . .	91
89	12.1.1 Wiederholen von Befehlen mit <code>for()</code> . . . . .	92
90	12.1.2 Wiederholen von Befehlen mit <code>while()</code> . . . . .	94
91	12.2 Bedingte Ausführung von Codeblöcken . . . . .	95

92	<b>13 (R)markdown</b>	<b>97</b>
93	13.1 Markdown Grundlagen . . . . .	97
94	13.2 R und Markdown . . . . .	98
95	<b>14 Räumliche Daten in R</b>	<b>100</b>
96	14.1 Was sind räumliche Daten . . . . .	100
97	14.2 Koordinatenbezugssystem . . . . .	100
98	14.3 Vektordaten in R . . . . .	101
99	14.4 Arbeiten mit Vektordaten . . . . .	102
100	14.5 Rasterdaten in R . . . . .	104
101	<b>15 FAQs (Oft gefragtes)</b>	<b>111</b>
102	15.1 Arbeiten mit Daten . . . . .	111
103	15.1.1 Einlesen von Exceldateien . . . . .	111
104	<b>16 Zusätzliche Aufgaben</b>	<b>112</b>
105	16.1 Arbeiten mit Daten . . . . .	114
106	<b>17 Literatur</b>	<b>116</b>

# 1 R und RStudio

## 1.1 Installation von R und RStudio

Als ersten Schritt müssen Sie R und RStudio installieren. Dabei ist wichtig zu unterscheiden, dass R und RStudio zwei unterschiedliche Programme sind. R ist die eigentliche Programmiersprache mit der wir arbeiten. RStudio hingegen ist eine sogenannte Entwicklungsumgebung<sup>1</sup>, die das Arbeiten mit R vereinfachen soll.

Wichtig ist, dass man kann mit R arbeiten ohne RStudio, aber man kann nicht mit RStudio arbeiten ohne R.

Gehen Sie für die Installation von R, auf die Website <https://cloud.r-project.org/> und laden Sie die für ihren Computer passende R-Version herunter und folgen Sie den Installationsanweisungen.

Für die Installation von RStudio, gehen Sie zu der Website (<https://posit.co/download/rstudio-desktop/#download>) und laden Sie wieder die richtige Version für Ihr Betriebssystem herunter und folgen Sie den Installationsanweisungen.

## 1.2 Erste Schritte in R

RStudio bietet eine Vielzahl von Funktionen, die uns das Arbeiten mit R erleichtern können. Öffnen Sie RStudio. Sie erhalten eine leere Entwicklungsumgebung. Als erstes bietet es sich an, ein neues Skript zu erstellen. Gehen Sie dafür auf das Menü: **File** » **New File** » **R Script** oder klicken Sie die Tastenkombination *Strg* + *Umschalt* + *N* (**Strg** + **⇧** + **N**).

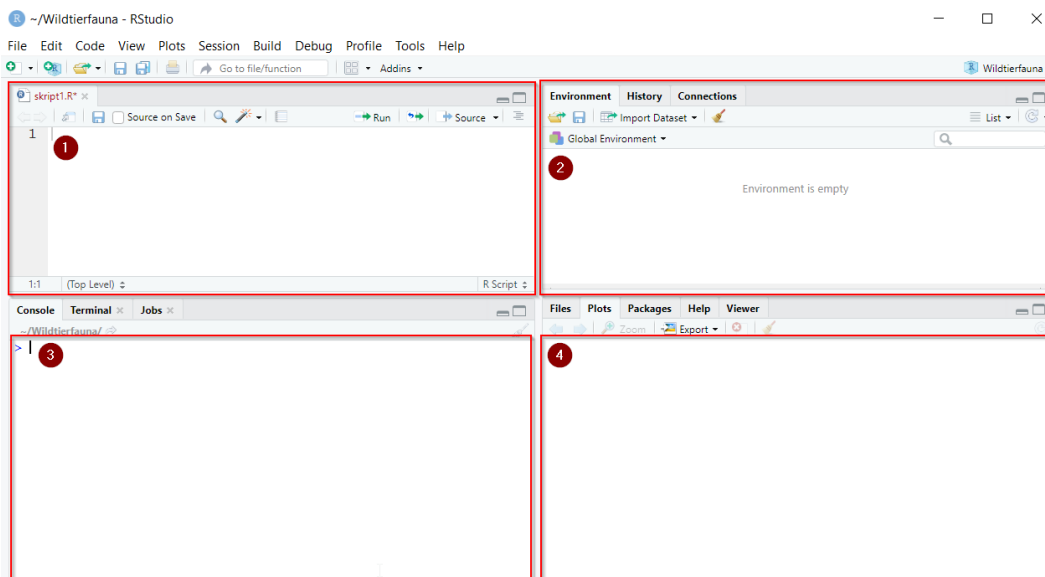


Abbildung 1: RStudio Panes.

<sup>1</sup>Oder auch IDE (=Integrated Development Environment) genannt.

RStudio besteht nun aus vier sogenannten Panes oder Ausschnitten (siehe auch Abbildung 1). Die Ausschnitte sind wie folgt gegliedert:

1. Hier werden Skripte angezeigt, d.h., hier wird meist R Code geschrieben und dokumentiert.
2. Der zweite Ausschnitt erteilt Auskunft über den *Workspace*. Im Workspace werden alle verfügbaren Objekte angezeigt.
3. Die eigentliche R-Konsole wird in Ausschnitt 3 dargestellt. Hier wird in der Regel wenig Code eingegeben. Der normale Workflow ist vom Skript Code an die Konsole zu schicken.
4. Der vierte Ausschnitt enthält mehrere Reiter. Der Reiter *Files* zeigt den Verzeichnisbaum an. Im Reiter *Plots* werden Plots angezeigt, wenn diese im Code aufgerufen werden. Hilfeseiten zu Funktionen werden im Reiter *Help* angezeigt.

Einfache Rechenoperationen lassen sich in der R-Konsole durchführen.

```
10 + 5
```

```
## [1] 15
```

```
20 - 10
```

```
## [1] 10
```

```
10 * 3
```

```
## [1] 30
```

```
100 / 19
```

```
## [1] 5.263158
```

Weitere häufig verwendete Operationen sind  $\wedge$  für eine beliebige Potenz, z.B.  $2^3 = 2^3 = 8$ . Analog dazu gibt es die Funktion `sqrt()` zum berechnen von Wurzeln und viele weitere Funktionen.

Meist verwenden wir jedoch Skripte, um den R-Code zu schreiben und ihn dann an die Konsole “zu schicken”. Dies hat den Vorteil, dass alle Schritte nachvollziehbar bleiben und Analysen beliebig oft wiederholt werden können. Nach der Ausführung bleibt der Code erhalten. Stellen Sie sich den Code im R-Skript wie ein Kochbuch vor. Wenn wir R-Code in einem R-Skript geschrieben haben gibt es mehrere Möglichkeiten diesen Code auszuführen. Wir können entweder auf *Run* drücken (Abbildung 2) oder den Code mit der Tastenkombination *Strg + Enter* (`(Strg) + [ ] + ↵`) an die Konsole schicken.

### 1.3 Kommentare

Ein wichtiger Bestandteil für das Arbeiten mit Skripten in R sind Kommentare. Ein Kommentar ist Text in einem R-Skript, der der Dokumentation dient und von der R Konsole ignoriert wird. Sämtliche Zeilen, die mit dem Zeichen `#` beginnen, werden ignoriert.



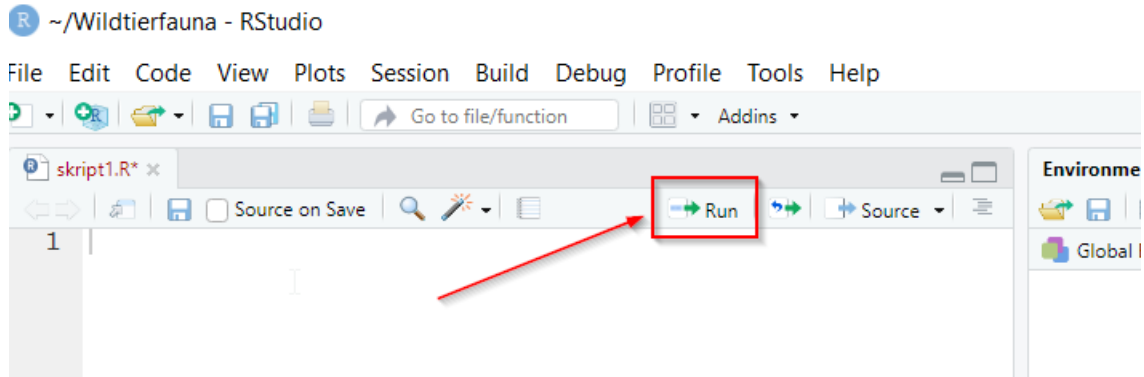


Abbildung 2: Ausführen von Code in RStudio..

```
# Berechnen der Quadratwurzel
sqrt(81)
```

```
## [1] 9
```

Im vorherigen Codeblock wurde der Funktionsaufruf `sqrt(a)` auskommentiert. Die Zeile `# Berechnen der Quadratwurzel` wird bei der Ausführung ignoriert. Es empfiehlt sich, komplexere Abläufe zu kommentieren damit andere (z.B. Kommilitonen / Kommilitoninnen) verstehen, warum und wie etwas gemacht wurde. Ganz besonders gilt das jedoch für einen selbst. Oft sind in der Zukunft Zusammenhänge nicht mehr so klar, wie sie beim Schreiben des Codes waren.

### Aufgabe 1: Ausführen von Quellcodes

Öffnen Sie RStudio, erstellen Sie ein neues Skript und speichern Sie dieses unter dem Namen `skript1.R` ab. Tippen oder kopieren Sie folgenden Code in das Skript:

```
# Einfache Rechenoperationen
1 + 3
2^7

# Einfache Funktion
sqrt(20)
```

Führen Sie nun alle Zeilen aus.

## 2 Variablen, Funktionen und Datentypen

### 2.1 Variablen beim Programmieren

Ergebnisse aus Berechnungen (wie oben angeführt), aber auch aus deutlich komplexeren Operationen, werden in Variablen abgespeichert. Man kann sich eine Variable wie eine Hülle (oder bildlich gesprochen wie eine Schachtel) vorstellen, in die man etwas hinein legen kann und darauf zu einem späteren Zeitpunkt wieder zugreifen kann. Z.B. weist der folgende Ausdruck der Variable `alter` den Wert 102 zu.

```
alter = 102
```

Variablen können Objekte in R speichern. Ein Objekt, im einfachsten Fall ein einzelner Wert, kann mit der Anweisung `<-` einer Variablen zugewiesen werden. Der nachfolgende Code weist der Variable `a` den Wert 10 zu.

```
a <- 10
a
```

```
## [1] 10
```

Man kann mit `=` oder `<-` einer Variable einen Wert zuweisen. Der Unterschied ist in den meisten Fällen vernachlässigbar, es wird aber allgemein empfohlen `<-` zu verwenden.

Wir können beliebige Variablen erstellen, z.B.

```
abc <- 10
name <- "Johannes"
```

Variablennamen dürfen mit keiner Zahl beginnen und müssen aus einem Wort bestehen.

- `a_123 <- 10` ist ok
- `123_a <- 10` erzeugt einen Fehler

Vorsicht: Groß- und Kleinschreibung muss beachtet werden

```
name <- "Johannes"
name
```

```
## [1] "Johannes"
```

Das Aufrufen der Variable

```
Name
```

führt zu einem Fehler.

Wir können dann mit den Werten, die in Variablen gespeichert sind, ganz normale Rechenoperationen durchführen.

```
a <- 10
b <- 5

a + b
```

```
## [1] 15
```

```
b / a
```

```
## [1] 0.5
```

```
a^b
```

```
## [1] 1e+05
```

Das Ergebnis kann natürlich wieder in einer neuen Variable gespeichert werden.

```
ergebnis <- a + b
ergebnis
```

```
## [1] 15
```

```
ergebnis2 <- ergebnis * 2
ergebnis2
```

```
## [1] 30
```

Mit der Funktion `rm()` können Variablen, die nicht mehr benötigt werden, wieder gelöscht werden.

## 2.2 Datentypen

Es wurde bereits erwähnt, dass Variablen als Objekte gespeichert werden. Objekte sind Datenstrukturen, die Objekte bzw. Messwerte aus der Realität abbilden. Wenn Sie beispielsweise eine Fotofalle in einem Wald ausbringen, dann hat diese Fotofalle einen Namen (z.B. `Kamera1`) und nach einiger Zeit im Wald wurden hoffentlich auch einige Fotos aufgenommen. Wir nehmen einmal an, dass nach drei Wochen 132 Fotos von Rehen gemacht wurden.

Wir können jetzt sowohl den Namen der Fotofalle, als auch die Anzahl Fotos die aufgenommen wurden, in zwei Variablen abspeichern.

```
kamera_name <- "Kamera_1"  
anzahl_rehe <- 132
```

201 In den zwei vorherigen Zeilen Code haben wir zwei Objekte (im Sinne von R) erstellt. Das erste Objekt heißt  
202 `kamera_name` und das zweite Objekt heißt `anzahl_rehe`. Auffällig ist, dass beide Objekte einen unterschied-  
203 lichen Datentyp haben. `kamera_name` ist vom Typ `character` (also Text). Das zweite Objekt, `anzahl_rehe`,  
204 ist vom Typ `numeric` (also eine Zahl, wir unterscheiden hier nicht weiter<sup>2</sup>). Zusätzlich zu diesen zwei Typen  
205 (`character` und `numeric`) gibt es noch einen dritten wichtigen Typ: nämlich das logische Wahr oder Falsch  
206 (in R: `TRUE` und `FALSE`). Zurückkommend auf das Beispiel mit den Fotofallen, könnte eine mögliche Frage-  
207 stellung sein, ob auf einem der Fotos ein Fuchs gesehen wurde oder nicht. Dazu würden wir wieder eine neue  
208 Variable `fuchs_gesehen` anlegen und diese auf `TRUE` setzen, da ein Fuchs gesehen wurde.

```
fuchs_gesehen <- TRUE
```

## 209 2.3 Funktionen

210 Ein zweiter wesentlicher Bestandteil beim Arbeiten mit R sind Funktionen. Während eine Variable etwas  
211 *speichert* tut eine Funktion etwas. Beispielsweise zieht die Funktion `sqrt()` die Quadratwurzel aus einer  
212 Zahl.

```
sqrt(a)
```

```
213 ## [1] 3.162278
```

214 Funktionen sind in R in der Regel daran zu erkennen, dass sie immer mit dem Funktionsnamen, gefolgt  
215 von runden Klammern (`()`), aufgerufen werden. Im vorherigen Beispiel wurde die Funktion mit dem Namen  
216 `sqrt()` aufgerufen. Das Objekt `a` haben wir bereits vorhin definiert (zur Erinnerung `a <- 10`). Die Funktion  
217 `sqrt()` arbeitet jetzt mit dem Objekt `a`, das in diesem Zusammenhang auch **Argument** genannt wird.

218 Argumente von Funktionen haben Namen, diese müssen jedoch nicht angegeben werden, wenn die Reihen-  
219 folge der Argumente berücksichtigt wird. Im vorherigen Beispiel, haben wir einfach die Funktion `sqrt(a)`  
220 aufgerufen und keinen Argumentnamen angegeben. Aus den Hilfeseiten für die Funktion `sqrt()` (siehe auch  
221 nachfolgender Abschnitt) ist zu entnehmen, dass die Funktion `sqrt()` ein Argument mit dem Namen `x` hat.  
222 Das heißt, der vollständige Aufruf der Funktion `x` wäre.

```
sqrt(x = a)
```

```
223 ## [1] 3.162278
```

224 Um mehr über eine Funktion zu erfahren (z.B. die Bedeutung von Argumenten zu verstehen oder heraus-  
225 zufinden, was eine Funktion zurück gibt), können wir die Hilfeseiten konsultieren. Es gibt unterschiedliche  
226 Wege, um zu einer Hilfeseite zu gelangen.

---

<sup>2</sup>Für Interessierte, man kann natürlich zwischen Ganzzahlen (`int`) und Gleitkommazahlen (`double`) unterscheiden.

1. In die Konsole `?<Name der Funktion>` tippen. Also, wenn wir Hilfe für die Funktion `mean()` möchten, könnten wir einfach `?mean` in die Konsole tippen.
2. Analog zu 1), können wir mit der Funktion `help` die Hilfeseite für eine andere Funktion aufrufen (z.B. wenn wir wieder die Hilfe für die Funktion `mean()` lesen möchten, dann könnten wir auch `help(mean)` in die Konsole tippen).
3. In RStudio kann man auch auf das **Help**-Panel klicken und dann einfach eine Funktion suchen (siehe Abbildung 1).
4. Wenn der Cursor in RStudio auf einer Funktion ist, kann man mit der Taste F1 die dazugehörige Hilfeseite aufrufen.

## 2.4 Datenstrukturen

Verfolgen wir das Beispiel mit den Fotofallen etwas weiter. Es handelt sich um ein systematisches Monitoring. D.h. es wurde nicht nur eine Fotofalle ausgebracht, sondern insgesamt 15 Stück. Dieser Umstand erfordert eine komplexere Datenstruktur. Nachfolgend sind die Anzahl Rehphotos für jede der 15 Fotofallen aufgeführt: 132, 79, 129, 91, 138, 144, 55, 103, 139, 105, 96, 146, 95, 118, 107.

Die Frage, die sich jetzt stellt, ist: Wie kann man diese Daten sinnvoll organisieren? Zusätzlich zur Anzahl der fotografierten Rehe soll jede Fotofalle eine eindeutige ID haben (`Kamera_1`, ..., `Kamera_15`) und wir wissen, dass jeweils 5 Fotofallen in drei unterschiedlichen Revieren aufgestellt waren (Fotofalle 1 bis 5 in Revier A, Fotofalle 6 bis 10 in Revier B und Fotofalle 11 bis 15 in Revier C).

Ein erster, wenn auch nicht wirklich sinnvoller, Ansatz könnte sein, dass wir für jede Fotofalle drei Objekte erstellen:

```
# 1. Kamera
name1 <- "Kamera_1"
anzahl_rehe1 <- 132
revier_1 <- "Revier A"

# 2. Kamera
name2 <- "Kamera_2"
anzahl_rehe2 <- 79
revier_2 <- "Revier A"

# usw.
```

Wenn wir so vorgehen würden, hätten wir 45 Objekte. Dieser Ansatz ist nicht sehr effizient und führt schnell zu einem unübersichtlichen *Workspace*<sup>3</sup>. Wir werden im Verlauf unterschiedliche Datenstrukturen kennenlernen.

<sup>3</sup>Als *Workspace* werden alle Objekte bezeichnet, die in einer R-Session zur Verfügung stehen.

250

251 **Aufgabe 2: Variablen**

---

252

253 Verwenden Sie die folgenden Daten

```
a <- 2
b <- "100"
p <- FALSE
```

254 und berechnen sie:

- 255 • `10 * a`
- 256 • `a / 144` und speichern Sie das Ergebnis in einer neuen Variablen `e` zwischen.
- 257 • Was ist das Ergebnis von `a + b`?
- 258 • Was ist das Ergebnis von `a + p`?

```
10 * a
e <- a / 144
a + b
a + p
```

259 **2.5 Funktionen**

260 Ein zweiter wesentlicher Bestandteil beim Arbeiten mit R sind Funktionen. Während eine Variable etwas  
261 *speichert* tut eine Funktion etwas. Beispielsweise zieht die Funktion `sqrt()` die Quadratwurzel aus einer  
262 Zahl.

```
sqrt(a)
```

263 

```
## [1] 1.414214
```

264 Funktionen sind in R in der Regel daran zu erkennen, dass sie immer mit dem Funktionsnamen, gefolgt  
265 von runden Klammern `()`, aufgerufen werden. Im vorherigen Beispiel wurde die Funktion mit dem Namen  
266 `sqrt()` aufgerufen. Das Objekt `a` haben wir bereits vorhin definiert (zur Erinnerung `a <- 10`). Die Funktion  
267 `sqrt()` arbeitet jetzt mit dem Objekt `a`, das in diesem Zusammenhang auch **Argument** genannt wird.

268 Argumente von Funktionen haben Namen, diese müssen jedoch nicht angegeben werden, wenn die Reihen-  
269 folge der Argumente berücksichtigt wird. Im vorherigen Beispiel, haben wir einfach die Funktion `sqrt(a)`  
270 aufgerufen und keinen Argumentnamen angegeben. Aus den Hilfeseiten für die Funktion `sqrt()` (siehe auch  
271 nachfolgender Abschnitt) ist zu entnehmen, dass die Funktion `sqrt()` ein Argument mit dem Namen `x` hat.  
272 Das heißt, der vollständige Aufruf der Funktion `x` wäre.

```
sqrt(x = a)
```

```
273 ## [1] 1.414214
```

274 Um mehr über eine Funktion zu erfahren (z.B. die Bedeutung von Argumenten zu verstehen oder heraus-  
275 zufinden, was eine Funktion zurück gibt), können wir die Hilfeseiten konsultieren. Es gibt unterschiedliche  
276 Wege, um zu einer Hilfeseite zu gelangen.

- 277 1. In die Konsole `?<Name der Funktion>` tippen. Also, wenn wir Hilfe für die Funktion `mean()` möchten,  
278 könnten wir einfach `?mean` in die Konsole tippen.
- 279 2. Analog zu 1), können wir mit der Funktion `help` die Hilfeseite für eine andere Funktion aufrufen (z.B.  
280 wenn wir wieder die Hilfe für die Funktion `mean()` lesen möchten, dann könnten wir auch `help(mean)`  
281 in die Konsole tippen).
- 282 3. In RStudio kann man auch auf das **Help**-Panel klicken und dann einfach eine Funktion suchen (siehe  
283 Abbildung 1).
- 284 4. Wenn der Cursor in RStudio auf einer Funktion ist, kann man mit der Taste F1 die dazugehörige  
285 Hilfeseite aufrufen.

## 3 Vektoren

Die gute Nachricht zuerst, Sie haben bereits Vektoren erstellt in R (und dies wahrscheinlich nicht bewusst wahrgenommen). Wenn Sie nämlich eine Variable erstellen (z.B., `a <- 10`), wird ein Vektor der Länge eins erstellt, das heißt der Vektor enthält genau ein Element.




Abbildung 3: Schematische Darstellung eines Vektors in R.

Sie können sich Vektoren wie einen Schubladenschrank vorstellen (siehe auch Abbildung 3). Wichtig ist dabei, dass man in jede Schublade immer nur ein Element vom gleichen Typ verstauen kann. Etwas allgemeiner gesprochen heißt das, dass alle Elemente eines Vektors vom gleichen Datentyp sein müssen.

Es gibt zahlreiche Funktionen zum Erstellen von Vektoren (einige davon werden wir im weiteren Verlauf des Moduls kennenlernen). Die wohl wichtigste Funktion ist `c()`. Dabei steht `c` für *combine* oder *concatenate*. Die Funktion `c()` fügt einzelne Elemente in einen Vektor zusammen (und zwar genau in der Reihenfolge wie diese Elemente an `c()` übergeben werden).

Gehen wir nochmals zurück zu Abbildung 3, da wird schematisch dargestellt wie ein Vektor `s` mit 7 Elementen (in diesem Fall Zahlen) erstellt werden kann.

```
s <- c(37, 1, 15, 2, 7, 19, 22)
```

Die Funktion `c()` ordnet jetzt bildlich gesprochen die Zahl 37 der ersten Schublade zu, die Zahl 1 der zweiten Schublade und so weiter. Wenn Sie jetzt einfach `s` in die Konsole tippen, können Sie alle Elemente von `s` sehen:



```
s
```

```
## [1] 37 1 15 2 7 19 22
```

In Abbildung 3b wird der Vektor `s` nochmals systematisch dargestellt. Dabei sieht man, dass 37 an der ersten Position des Vektors gespeichert wird und 22 an der letzten Position des Vektors gespeichert wird.

Die Grundrechenarten (+, -, /, \*) und viele andere Funktionen funktionieren genau gleich mit Vektoren deren Länge > 1 ist. Sie werden elementweise durchgeführt. Wir können beispielsweise zu jedem Element von `s` 10 addieren

```
s + 10
```

```
## [1] 47 11 25 12 17 29 32
```

oder `s` mit sich selbst multiplizieren.

```
s * s
```

```
## [1] 1369 1 225 4 49 361 484
```

Neben der Funktion `c()` gibt es zahlreiche weitere Funktionen, um Vektoren zu erstellen. Sehr häufig braucht man Vektoren von Zahlenfolgen, solche Vektoren können mit der Funktion `seq` erstellt werden. Im einfachsten Fall benötigt `seq()` zwei Argumente: `from` und `to`<sup>4</sup>.

```
seq(from = 1, to = 10)
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

Man kann dann auch noch die Schritte angeben, mit denen erhöht wird.

```
seq(from = 1, to = 10, by = 2)
```

```
## [1] 1 3 5 7 9
```

```
317
```

### Aufgabe 3: Vektoren erstellen

Sie haben den BHD (Brusthöhendurchmesser) in cm von vier Bäumen gemessen: 13, 15.3, 23, 9

- Erstellen Sie einen Vektor mit dem Namen `bhd` in dem Sie die Werte speichern
- Transformieren sie die BHD-Werte in mm.
- Berechnen Sie die Fläche des BHD in  $cm^2$  (nehmen Sie dafür an, dass ein Baum kreisrund ist).

<sup>4</sup>Weil solche Vektoren so häufig vorkommen gibt es hier eine Abkürzung. Man kann `seq(from, to, by = 1)` mit `from:to` abkürzen. Also `1:10` würde auch alle Zahlen von 1 bis 10 zurückgeben.

### 3.1 Funktionen zum Arbeiten mit Vektoren

Die Funktionen `head()` und `tail()` geben die ersten bzw. letzten `n` Elemente eines Vektors zurück. `n` hat einen voreingestellten Wert von 6, dieser kann natürlich angepasst werden.

```
head(s)
```

```
## [1] 37  1 15  2  7 19
```

```
head(s, n = 3)
```

```
## [1] 37  1 15
```

```
tail(s, n = 2)
```

```
## [1] 19 22
```

Die Funktion `length()` gibt die Länge eines Vektors wieder.

```
length(s)
```

```
## [1] 7
```

Der Typ der Elemente eines Vektors kann mit der Funktion `class` abgefragt werden:

```
class(s)
```

```
## [1] "numeric"
```

Die eindeutigen Elemente eines Vektors können mit der Funktion `unique()` abgefragt werden.

```
unique(s)
```

```
## [1] 37  1 15  2  7 19 22
```

Mit der Funktion `table` kann die Häufigkeit verschiedener Elemente abgefragt werden.

```
table(s)
```

```
## s
```

```
##  1  2  7 15 19 22 37
```

```
##  1  1  1  1  1  1  1
```

Schlussendlich kann man mit der Funktion `sort()` und `rev()` die Position von Elementen in einem Vektor ändern. Die Funktion `rev` dreht die Elemente einmal um

```
rev(s)
```

```
## [1] 22 19 7 2 15 1 37
```

während `sort()` einen Vektor nach seinen Elementen sortiert<sup>5</sup>.

```
sort(s)
```

```
## [1] 1 2 7 15 19 22 37
```

Die Funktion `rep()` wiederholt einen Vektor.

```
rep(s, times = 2)
```

```
## [1] 37 1 15 2 7 19 22 37 1 15 2 7 19 22
```

Anstelle des Arguments `times` kann auch das Argument `each` verwendet werden. Der Unterschied liegt darin, dass `times` den gesamten Vektor `times`-Mal wiederholt und `each` jedes Element.

```
a <- 1:4  
rep(a, times = 2)
```

```
## [1] 1 2 3 4 1 2 3 4
```

```
rep(a, each = 2)
```

```
## [1] 1 1 2 2 3 3 4 4
```

351

#### Aufgabe 4: Arbeiten mit Vektoren

Es liegen jeweils zwei BHD-Messungen von vier Bäumen vor:

```
bhd <- c(32, 33, 23, 21, 21, 27, 18, 12)
```

Diese wurden immer abwechselnd mit zwei unterschiedlichen Messgeräten durchgeführt wurden.

Erstellen Sie einen Vektor von der Länge 8 mit den Einträgen die immer abwechselnd G1 und G2 sind und für die zwei Geräte stehen.

---

<sup>5</sup>Auch für `sort()` gibt es ein zusätzliches Argument, das es ermöglicht die Elemente in absteigender Reihenfolge zu sortieren. Schauen Sie sich dazu, und auch für weitere Funktionen, die Hilfeseiten an.

## 3.2 Statistische Funktionen

Zahlreiche statistische Funktionen können auf Vektoren angewendet werden, hier sind nur die wichtigsten aufgeführt: `mean()` berechnet den Mittelwert, `median()` berechnet den Median und `sd()` die Standardabweichung.

```
mean(s)
```

```
## [1] 14.71429
```

```
median(s)
```

```
## [1] 15
```

```
sd(s)
```

```
## [1] 12.76341
```

Eine weitere sehr häufig verwendete Funktion ist `sample()`. Mit `sample()` werden `size` Elemente zufällig aus einem Vektor, mit oder ohne Zurücklegen (mit Zurücklegen wird gezogen, wenn das Argument `replace = TRUE` gesetzt wird), gezogen.

```
sample(s, size = 1) # 1 Element
```

```
## [1] 1
```

```
sample(s, size = 3) # 3 Elemente
```

```
## [1] 15 7 22
```

Wenn `size` weggelassen wird, dann bekommt man gleich viele Elemente zurück (wie der Vektor lang ist), d.h. der Vektor wird nur permutiert.

## 3.3 Beispiel Fotofallen

Für den weiteren Verlauf wollen wir noch einmal zu dem Beispiel mit den Fotofallen zurückkommen. Wir können jetzt 3 Vektoren erstellen, jeweils einen für die ID, die Anzahl Rehphotos und das Revier. Dabei werden zwei weitere Funktionen eingeführt (`paste` und `rep`).

Als erstes erstellen wir einen Vektor mit den Anzahlen Rehphotos. Das geht einfach mit `c()`:

```
anzahl_rehe <- c(132, 79, 129, 91, 138, 144, 55, 103, 139,
                105, 96, 146, 95, 118, 1007)
```

377 Als zweites erstellen wir einen Vektor mit den IDs. Zur Erinnerung, diese sollten die Werte Kamera\_1 bis  
 378 Kamera\_15 haben. Ein erster Ansatz könnte sein, dass wir einfach 15 Fotofallen schreiben und dann die  
 379 Zahlen 1 bis 15 dahinter.

```
ids <- c("Kamera_1", "Kamera_2", "Kamera_3", "Kamera_4", "Kamera_5",
        "Kamera_6", "Kamera_7", "Kamera_8", "Kamera_9", "Kamera_10",
        "Kamera_11", "Kamera_12", "Kamera_13", "Kamera_14", "Kamera_15"
)
```

380 Dieser Ansatz ist unbefriedigend, da wir 15 mal das Wort “Kamera” tippen müssen. Wir können das Problem  
 381 in zwei kleinere Probleme zerlegen: 1) 15 mal das Wort Kamera erstellen und die Zahlen 1 bis 15 erstellen,  
 382 2) die zwei Vektoren aus 1) “zusammenkleben”.

383 Ein Vektor kann mit der Funktion `rep` wiederholt werden, das heißt wir können ganz einfach 15 mal das  
 384 Wort “Kamera” erstellen und speichern das Zwischenergebnis in einem Vektor `v1`.

```
v1 <- rep("Kamera", 15)
```

385 Im nächsten Schritt müssen wir die Zahlen 1 bis 15 erstellen, auch dieses Zwischenergebnis speichern wir in  
 386 einem neuen Vektor `v2`.

```
v2 <- 1:15
```

387 Jetzt müssen wir lediglich die Vektoren `v1` und `v2` “zusammenkleben”. Dafür gibt es die Funktion `paste`,  
 388 die zwei Vektoren elementweise verbindet, dabei wird das Argument `sep` als Trennzeichen verwendet. In  
 389 unserem Fall wäre das also.

```
ids <- paste(v1, v2, sep = "_")
ids
```

```
390 ## [1] "Kamera_1" "Kamera_2" "Kamera_3" "Kamera_4" "Kamera_5" "Kamera_6"
391 ## [7] "Kamera_7" "Kamera_8" "Kamera_9" "Kamera_10" "Kamera_11" "Kamera_12"
392 ## [13] "Kamera_13" "Kamera_14" "Kamera_15"
```

393 Dann fehlt jetzt lediglich der Vektor mit den Revieren. Hier könnten wir erneut auf die Funktion `rep`  
 394 zurückgreifen.

```
rep(c("Revier A", "Revier B", "Revier C"), 5)
```

```
395 ## [1] "Revier A" "Revier B" "Revier C" "Revier A" "Revier B" "Revier C"
396 ## [7] "Revier A" "Revier B" "Revier C" "Revier A" "Revier B" "Revier C"
397 ## [13] "Revier A" "Revier B" "Revier C"
```

398 Das Ergebnis stimmt noch nicht ganz, da wir 5 mal Revier A usw. brauchen. Mit dem zusätzlichen Argument  
 399 `each = 5` können wir genau zu diesem Ergebnis kommen.

```
reviere <- rep(c("Revier A", "Revier B", "Revier C"), each = 5)
reviere
```

```
400 ## [1] "Revier A" "Revier A" "Revier A" "Revier A" "Revier A" "Revier B"
401 ## [7] "Revier B" "Revier B" "Revier B" "Revier B" "Revier C" "Revier C"
402 ## [13] "Revier C" "Revier C" "Revier C"
```

403

#### 404 *Aufgabe 5: Statistische Funktionen*

405

406 1. Berechnen Sie den Mittelwert und Median für die Anzahl Fotos.

407 2. Erstellen Sie die folgende Ausgabe:

```
408 ## [1] "Die mittlere Anzahl von Rehphotos beträgt 171.8 Rehe pro Standort."
```

### 409 3.4 Arbeiten mit logischen Werten

410 Weniger bekannt sind die sogenannte booleschen Rechenregeln, also das Rechnen mit wahr (TRUE) und falsch  
 411 (FALSE). Dabei werden die folgenden Operationen am häufigsten verwendet.

- 412 • Gleichheit (==)
- 413 • Ungleichheit (!=)
- 414 • Größer (>) und kleiner (<)
- 415 • Größer gleich (>=) und kleiner gleich (<=)

416 Das Ergebnis von logischen Operatoren ist immer TRUE oder FALSE.

417 Bei Vektoren kommt es immer zu einer elementweisen Anwendung. Wir können beispielsweise abfragen an  
 418 welchen Fotofallenstandorten mehr als 100 Rehe fotografiert wurden oder

```
anzahl_rehe > 100
```

```
419 ## [1] TRUE FALSE TRUE FALSE TRUE TRUE FALSE TRUE TRUE TRUE FALSE TRUE
420 ## [13] FALSE TRUE TRUE
```

421 welche Fotofallenstandorte sich in Revier B befinden.

```
reviere == "Revier B"
```

```
422 ## [1] FALSE FALSE FALSE FALSE FALSE TRUE TRUE TRUE TRUE TRUE FALSE FALSE
423 ## [13] FALSE FALSE FALSE
```

424 Des Weiteren können logische Ausdrücke miteinander verknüpft werden. Dies geschieht mit einem logischen  
 425 Und (&) oder einem logischen Oder (|). Für das logische Und müssen beide Ausdrücke ein TRUE zurückgeben  
 426 um ein TRUE zu erhalten. Für ein logisches Oder reicht es, wenn einer der beiden Ausdrücke TRUE zurückgibt,  
 427 um ein TRUE zu erhalten.

428 Damit können wir nun z.B. die beiden vorherigen Abfragen verbinden. Die erste Abfrage ist: Hat eine Fotofalle  
 429 mehr als 100 Rehe fotografiert und stand die Fotofalle in Revier B.

```
anzahl_rehe > 100 & reviere == "Revier B"
```

```
430 ## [1] FALSE FALSE FALSE FALSE FALSE TRUE FALSE TRUE TRUE TRUE FALSE FALSE
431 ## [13] FALSE FALSE FALSE
```

432 Das war jetzt eine Abfrage mit einem logischen Und. Würden wir ein logisches Oder verwenden, dann  
 433 bekommen wir für alle Elemente ein TRUE, die entweder in Gebiet B stehen oder mehr als 100 Rehfotos  
 434 aufgezeichnet haben.

```
anzahl_rehe > 100 | reviere == "Revier B"
```

```
435 ## [1] TRUE FALSE TRUE FALSE TRUE TRUE TRUE TRUE TRUE TRUE FALSE TRUE
436 ## [13] FALSE TRUE TRUE
```

437 Das Arbeiten mit logischen Werten kann fürs Erste etwas abstrakt erscheinen, aber wir werden im folgenden  
 438 Abschnitt (Abschnitt 3.5) zahlreiche Anwendungsbeispiele dafür sehen.

439 TRUE wird intern als 1 gespeichert und FALSE als 0. Es ist möglich mit TRUEs und FALSEs zu rechnen.

```
TRUE + TRUE
```

```
440 ## [1] 2
```

```
FALSE + FALSE
```

```
441 ## [1] 0
```

```
TRUE + FALSE
```

```
442 ## [1] 1
```

**Aufgabe 6: Arbeiten mit logischen Werten**

Überlegen Sie für jede Aufgabe erst was das richtige Ergebnis ist und Überprüfen Sie dieses dann mit R.

1. TRUE | FALSE
2. FALSE & TRUE
3. (FALSE & TRUE) | TRUE
4. (2 != 3) | FALSE
5. FALSE + 10
6. TRUE + 10
7. TRUE + 10 == FALSE + 10
8. sum(c(TRUE, TRUE, FALSE, FALSE))

**3.5 Zugreifen auf Elemente eines Vektors (=Untermengen)**

Sehr oft wollen wir auf bestimmte Werte in einer Datenstruktur zugreifen. Beispielsweise könnte es uns interessieren, wieviele Rehe im Mittel auf allen Fotofallen aus Revier A gesehen wurden.

Bei Vektoren kann auf die einzelnen Elemente mit eckigen Klammern ([ ]), diese werden auch Indizierungs-  
klammern genannt) zugegriffen werden. Der Ausdruck `anzahl_rehe[2]` gibt die Anzahl an fotografierten  
Rehen für die zweite Fotofalle zurück. Es gibt zwei Möglichkeiten, was in die eckigen Klammern geschrieben  
werden kann: 1) die Positionen der Elemente die man zurückhaben möchte. Ist es mehr als ein Element,  
dann muss man einfach einen Vektor mit den Positionen übergeben; 2) ein logischer Vektor von der gleichen  
Länge, es werden alle Elemente zurückgegeben bei denen ein TRUE steht.

Abfragen des zweiten Elements in dem Vektor `anzahl_rehe`:

```
anzahl_rehe[2]
```

```
## [1] 79
```

Abfragen aller Elemente aus `anzahl_rehe`, die aus dem Revier A stammen.

```
anzahl_rehe[c(1, 2, 3, 4, 5)]
```

```
## [1] 132 79 129 91 138
```

```
# oder schneller
```

```
anzahl_rehe[1:5] # da `1:5` einen Vektor mit allen Zahlen von 1 bis 5 erstellt.
```

```
## [1] 132 79 129 91 138
```

Hier ist nochmals hervorzuheben, dass innerhalb der eckigen Klammer mit dem Befehl `c(1, 2, 3, 4, 5)`  
bzw. `1:5` ein Vektor erstellt wird, der die Position der Elemente angibt, die zurückgegeben werden sollen.



471

### 472 *Aufgabe 7: Zugreifen auf Vektorelemente*

473

474 Erstellen Sie einen neuen Vektor `bhd`

```
bhd <- c(12, 32, 39, 41, 12, 30)
```

475

- Wählen Sie aus dem Vektor `bhd` nur das 2. und 3. Element aus.

476

- Wählen Sie aus dem Vektor `bhd` das letzte Element aus.

477

- Wählen Sie aus dem Vektor `bhd` das letzte Element aus, ohne die Zahl 6 zu schreiben.

478

479 Alternativ könnte das gleiche Ergebnis mit einem logischen Vektor erreicht werden. Für eine bessere Über-  
480 sichtlichkeit wird erst ein Vektor `sub` erstellt, in dem die logischen Werte gespeichert werden:

```
sub <- c(TRUE, TRUE, TRUE, TRUE, TRUE, FALSE, FALSE, FALSE,
        FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE)
anzahl_rehe[sub]
```

```
## [1] 132 79 129 91 138
```

482 Das Erstellen des `sub`-Vektors ist mühsam und wenig zielführend. Wenn wir auf die Erkenntnisse aus dem  
483 vorherigen Kapitel zurückgreifen, kann dies leicht automatisiert werden, indem wir einfach abfragen, welche  
484 Elemente in Revier zu Revier A gehören.

```
sub <- reviere == "Revier A"
anzahl_rehe[sub]
```

```
## [1] 132 79 129 91 138
```

486 Das kann nochmals vereinfacht werden, indem wir den Hilfsvektor `sub` einfach weglassen und den Ausdruck  
487 direkt in die eckigen Klammern ziehen.

```
anzahl_rehe[reviere == "Revier A"]
```

```
## [1] 132 79 129 91 138
```

489 Wenn wir jetzt noch den Mittelwert der Anzahl fotografierten Rehe aus Revier A bilden möchten, erweitert  
490 sich der Ausdruck um einen Funktionsaufruf zur Funktion `mean`.

```
mean(anzahl_rehe[reviere == "Revier A"])
```

```
## [1] 113.8
```

```
492
```

### Aufgabe 8: logische Werte

Verwenden Sie nochmals den Vektor mit den Anzahl Rehen die an unterschiedlichen Fotofallenstandorten fotografiert wurden.

```
anzahl_rehe <- c(132, 79, 129, 91, 138, 144, 55, 103, 139, 105, 96, 146, 95, 118, 107)
```

1. Wählen Sie alle Standorte aus für die Aussage zu  $90 \leq x < 120$  zu trifft (wobei  $x$  für die Anzahl Fotos an einem Standort steht).
2. Berechnen Sie die mittlere Anzahl Fotos für alle in 1) ausgewählten Standorte.

## 3.6 Der %in%-Operator

Häufig wollen wir mehrere Elemente aus einem Vektor auswählen, die in einem anderen Vektor enthalten sind. Als einfaches Beispiel nehmen wir zwei Vektoren:

```
arten <- c("FI", "BU")
messungen_arten <- c("FI", "BU", "BU", "EI", "EI", "BI", "FI", "BI", "EI")
```

Wenn wir aus dem Vektor `messungen_arten` alle `FI` auswählen wollen, können wir dies mit einem logischen `==` machen:

```
messungen_arten[messungen_arten == "FI"]
```

```
## [1] "FI" "FI"
```

```
# oder
messungen_arten[messungen_arten == arten[1]]
```

```
## [1] "FI" "FI"
```

Etwas komplizierter wird es, wenn wir zwei oder mehr Elemente auswählen wollen. Dies geht auch mit logischen Operationen.

```
messungen_arten[messungen_arten == arten[1] | messungen_arten == arten[2]]
```

```
509 ## [1] "FI" "BU" "BU" "FI"
```

510 Diese Herangehensweise wird aber für > 2 Elemente in `arten` sehr mühsam. Eine Alternative bietet der  
511 `%in%`-Operator. Dieser testet, ob Elemente eines Vektors in einem zweiten Vektors enthalten sind.

```
messungen_arten %in% arten
```

```
512 ## [1] TRUE TRUE TRUE FALSE FALSE FALSE TRUE FALSE FALSE
```

```
messungen_arten[messungen_arten %in% arten]
```

```
513 ## [1] "FI" "BU" "BU" "FI"
```

514

515 *Aufgabe 9: Auswählen von Elementen in einem Vektor (%in%)*  
516

---

517 Der Vector `LETTERS` ist in R vorhanden und enthält die Buchstaben von A bis Z.

```
LETTERS
```

```
518 ## [1] "A" "B" "C" "D" "E" "F" "G" "H" "I" "J" "K" "L" "M" "N" "O" "P" "Q" "R" "S"
```

```
519 ## [20] "T" "U" "V" "W" "X" "Y" "Z"
```

520 Wählen Sie aus `LETTERS` nur die Vokale aus.

## 4 Faktoren (factors)

R besitzt einen besonderen Datentyp – *Faktoren* (engl. factors) – zum speichern von diskreten Kovariaten (z.B. Baumart, Augenfarbe oder Automarke). Faktoren erlauben es Daten vom Typ `character` effizienter abzuspeichern. Dabei wird jeder eindeutiger Wert (=Level) mit einer Zahl codiert und dann werden nur diese Zahlen zusammen mit einer Tabelle zum Nachschauen der Werte gespeichert (siehe dazu auch [McNamara and Horton 2018](#)).

Mit der Funktion `factor()` kann ein Faktor erstellt werden. Im einfachsten Fall wird nur ein Vektor übergeben.

```
a <- c("FI", "BU", "FI", "EI", "EI", "FI", "FI")
factor(a)
```

```
## [1] FI BU FI EI EI FI FI
## Levels: BU EI FI
```

Ohne weitere Spezifikation werden die Werte *Levels* alphabetisch angeordnet (das kann später z.B. beim Erstellen von Abbildungen wichtig sein), dies kann jedoch durch die Verwendung des Arguments `levels` gesteuert werden.

```
factor(a, levels = c("FI", "BU", "EI"))
```

```
## [1] FI BU FI EI EI FI FI
## Levels: FI BU EI
```

Es ist auch möglich die Beschriftung (= labels) der unterschiedlichen Levels anzugeben mit dem Argument `labels`.

```
af <- factor(a, levels = c("FI", "BU", "EI"),
             labels = c("Fichte", "Buche", "Eiche"))
af
```

```
## [1] Fichte Buche Fichte Eiche Eiche Fichte Fichte
## Levels: Fichte Buche Eiche
```

Mit der Funktion `levels()` können die unterschiedlichen Levels eines Faktors abgefragt bzw. gesetzt werden.

```
levels(af)
```

```
## [1] "Fichte" "Buche" "Eiche"
```

```
levels(af) <- c("Fi", "Bu", "Ei")
af
```

```
## [1] Fi Bu Fi Ei Ei Fi Fi
## Levels: Fi Bu Ei
```

Schlussendlich kann man mit der Funktion `relevel()` die Referenzkategorie eines Faktors (der erste Level) angepasst werden. Das ist kann für lineare Modell wichtig sein.

```
af
```

```
## [1] Fi Bu Fi Ei Ei Fi Fi
## Levels: Fi Bu Ei
```

```
relevel(af, "Bu")
```

```
## [1] Fi Bu Fi Ei Ei Fi Fi
## Levels: Bu Fi Ei
```

Mit der Funktion `as.character()` kann ein Faktor wieder als Variable vom Typ `character` dargestellt werden.

```
as.character(af)
```

```
## [1] "Fi" "Bu" "Fi" "Ei" "Ei" "Fi" "Fi"
```

Achtung mit der Funktion `as.numeric()` erhält man die interne Kodierung von Faktoren.

```
af
```

```
## [1] Fi Bu Fi Ei Ei Fi Fi
## Levels: Fi Bu Ei
```

```
as.numeric(af)
```

```
## [1] 1 2 1 3 3 1 1
```

Fichte ist das erste Level des Faktors, deshalb erhalten alle Fichteneinträge den Wert 1. Bucheinträge erhalten den Wert 2 und 3 für Eichen.

559

---

**Aufgabe 10: Faktoren**

---

562 Verwenden Sie den Vektor `staedte` und erstellen Sie einen Vektor mit der Anordnung der `levels` in umge-  
563kehrter alphabetischer Reihenfolge.

```
staedte <- c("Berlin", "Aachen", "Berlin", "Ulm", "Aachen",  
            "Berlin", "Berlin", "Aachen", "Ulm", "Ulm")
```

## 5 Spezielle Einträge

In vielen Fällen werden spezielle Einträge benötigt, bspw. bei

- fehlenden Einträge `NA`,
- leeren Einträgen `NULL`,
- undefinierten Einträgen `NaN` (Not a Number) oder
- unendlichen Zahlen (`Inf`).

Spezielle Einträge sind reservierte Namen. Sie können nicht überschrieben werden.

### 5.1 NA

R verfügt über einen speziellen Wert für fehlende Einträge. Auch wenn in Vektoren eigentlich nur ein Datentyp erlaubt ist, sind `NA` zwischen den anderen Einträgen erlaubt. Der Datentyp des Vektors wird durch `NA` Einträge nicht verändert.

```
na1 <- c("foo", NA, "foo")
str(na1)
```

```
## chr [1:3] "foo" NA "foo"
```

```
na2 <- c(3, 6, NA)
str(na2)
```

```
## num [1:3] 3 6 NA
```

Der logische Operator zum Test auf fehlende Wert ist `is.na()`. Dieser kann genauso wie die bereits bekannten logischen Operatoren bspw. zum Filtern verwendet werden. Die `na.omit()` Funktion entfernt `NA` aus dem Datensatz.

```
is.na(na1)
```

```
## [1] FALSE TRUE FALSE
```

```
na.omit(na1)
```

```
## [1] "foo" "foo"
```

```
## attr(,"na.action")
```

```
## [1] 2
```

```
## attr(,"class")
```

```
## [1] "omit"
```

Die bereits bekannten logischen Operationen ergeben NA, wenn Sie auf Daten angewendet werden, die NA enthalten. Berechnungen mit NA ergeben ebenfalls NA. Bei der angewandten Programmierung müssen sie also darauf achten, dass Ihre Daten frei von NA sind oder sie fangen die NA vorher ab.

```
na2 < 3
```

```
## [1] FALSE FALSE    NA
```

```
1 + NA
```

```
## [1] NA
```

Viele R Funktionen haben eingebaute Methoden zum Umgang mit NA. Die Funktion `mean()` bspw. ergibt (wie die meisten Funktionen) standardmäßig NA wenn sie auf Vektoren mit Datenlücken angewendet wird, es sei denn man stellt innerhalb der Funktion ein, dass Datenlücken entfernt werden sollen.

```
mean(na2)
```

```
## [1] NA
```

```
mean(na2, na.rm = TRUE)
```

```
## [1] 4.5
```

## 5.2 NULL

Im Gegensatz zu NA wird NULL für leere Einträge verwendet, und nicht für fehlende Einträge. Da in der Mathematik leere Einträge und fehlende Einträge unterschiedliche Informationen darstellen, können diese beiden Fälle unterschieden werden. Mit der Funktion `is.null()` kann man überprüfen, ob ein Element in einem Vektor NULL ist oder nicht.

## 5.3 Inf

Die größtmögliche Zahl in R ist  $1.7976931 \cdot 10^{308}$ . Größere Zahlen werden als unendlich gespeichert.

```
10^309
```

```
## [1] Inf
```

```
2 * Inf
```

```
## [1] Inf
```



```
1 + Inf
```

```
## [1] Inf
```

```
3 / 0
```

```
## [1] Inf
```

```
-3 / 0
```

```
## [1] -Inf
```

```
3 / Inf
```

```
## [1] 0
```

Infinity kann mit `is.infinite` und `is.finite` getestet werden. Relationäre Operatoren funktionieren erwartungsgemäß.

```
inf1 <- c(Inf, 0, 3, -Inf, 10)
is.infinite(inf1)
```

```
## [1] TRUE FALSE FALSE TRUE FALSE
```

```
is.finite(inf1)
```

```
## [1] FALSE TRUE TRUE FALSE TRUE
```

```
inf1 < 3
```

```
## [1] FALSE TRUE FALSE TRUE FALSE
```

```
614
```

### *Aufgabe 11: Vektoren mit speziellen Einträgen*

Verwenden Sie den Vektor

```
foo <- c(13563, -13156, -14319, 16981, 12921, 11979, 9568, 8833, -12968, 8133)
```

- Nehmen Sie jeden Eintrag hoch 75. Filtern Sie alle unendlichen Einträge aus dem Vektor.
- Wie viele Einträge sind unendlich negativ?

Verwenden Sie den Vektor

```
foo <- c(4.3, 2.2, NULL, 2.4, NaN, 3.3, 3.1, NULL, 3.4, NA, Inf)
```

621 Sind die folgenden Einträge richtig oder falsch? Überlegen Sie zunächst selbst bevor Sie die Aussagen in R  
622 testen.

- 623 • Die Länge des Vektors ist 9.
- 624 • `is.na()` ergibt 2 Mal TRUE.
- 625 • `foo[9] + 4 / Inf` ergibt NA

626 Berechnen Sie den arithmetischen Mittelwert von `foo`.

## 6 data.frames oder Tabellen

Im vorherigen Teilabschnitt haben wir gesehen, wie mehrere Werte des gleichen Typs in einem Vektor zusammengefasst werden können. Abschließend wurde anhand des Fotofallenbeispiels gezeigt, wie Vektoren eingesetzt werden können. Wir erstellten drei Vektoren, die jeweils die Merkmalsausprägungen eines Merkmals aller Fotofallenstandorte speichern. In statistischer Sprache, sind die Fotofallen die Beobachtungen (oder auch Merkmalsträger genannt) und die Informationen zu den Fotofallen (also ID, Anzahl Rehe und das Revier) die Merkmale. Jeder beobachtete Wert (z.B. die 132 fotografierten Rehe von Kamera 1) ist dann eine Merkmalsausprägung.

Sie können sich ein `data.frame` wie eine Tabelle aus einem Tabellenkalkulationsprogramm vorstellen. Es gibt Zeilen in denen die Beobachtungen gespeichert sind und Spalten, die die Merkmale speichern. In unserem Fall gäbe es 15 Zeilen (eine Zeile für jede Fotofalle) und drei Spalten (jeweils eine Spalte für ID, Anzahl Rehe und Revier). Der Befehl zum Erstellen eines `data.frames` in R ist `data.frame()`. Für unser Beispiel wäre es:

```
monitoring <- data.frame(
  ID = ids,
  anzahl_rehe = anzahl_rehe,
  revier = reviere
)
monitoring
```

	ID	anzahl_rehe	revier
## 1	Kamera_1	132	Revier A
## 2	Kamera_2	79	Revier A
## 3	Kamera_3	129	Revier A
## 4	Kamera_4	91	Revier A
## 5	Kamera_5	138	Revier A
## 6	Kamera_6	144	Revier B
## 7	Kamera_7	55	Revier B
## 8	Kamera_8	103	Revier B
## 9	Kamera_9	139	Revier B
## 10	Kamera_10	105	Revier B
## 11	Kamera_11	96	Revier C
## 12	Kamera_12	146	Revier C
## 13	Kamera_13	95	Revier C
## 14	Kamera_14	118	Revier C
## 15	Kamera_15	107	Revier C

Im vorhergehenden Codebeispiel wurde ein `data.frame` erstellt und in die Variable `monitoring` gespeichert. Die Funktion `data.frame()` nimmt als Argumente beliebig viele Paare, die immer aus einem Namen und einem Vektor mit dazugehörigen Werten bestehen. D.h., dass immer eine Spalte vom selben Typ sein muss, es aber für jede Beobachtung (=Zeile) Merkmale von unterschiedlichen Typen geben kann.

## 6.1 Wichtige Funktionen zum Arbeiten mit `data.frames`

Wichtige Funktionen um das Arbeiten mit `data.frames` zu erleichtern sind wieder `head()` und `tail()`, um die ersten bzw. letzten `n` Zeilen eines `data.frames` anzuzeigen.

```
head(monitoring, n = 2)
```

```
##           ID anzahl_rehe   revier
## 1 Kamera_1          132 Revier A
## 2 Kamera_2           79 Revier A
```

Oder für die letzten 2 Beobachtungen.

```
tail(monitoring, 2)
```

```
##           ID anzahl_rehe   revier
## 14 Kamera_14          118 Revier C
## 15 Kamera_15          107 Revier C
```

Mit den Funktion `nrow()` und `ncol()` können die Anzahl Zeilen und die Anzahl Spalten abgefragt werden:

```
nrow(monitoring)
```

```
## [1] 15
```

```
ncol(monitoring)
```

```
## [1] 3
```

Mit der Funktion `str()` (kurz für *structure*) kann schnell ein Überblick über sämtliche Variablen verschafft werden.

```
str(monitoring)
```

```
## 'data.frame':   15 obs. of  3 variables:
## $ ID          : chr  "Kamera_1" "Kamera_2" "Kamera_3" "Kamera_4" ...
## $ anzahl_rehe: num  132 79 129 91 138 144 55 103 139 105 ...
## $ revier      : chr  "Revier A" "Revier A" "Revier A" "Revier A" ...
```

### Aufgabe 12: `data.frame`

Stellen Sie sich vor, Sie machen eine kleine Umfrage, in der Sie fünf Menschen nach ihrem Studienfach, Semester und Alter befragen. Erstellen Sie ein `data.frame` mit dem Namen `umfrage1` für diese Informationen und fragen Sie entweder fünf Mitstudierende oder erfinden Sie die Daten einfach.

## 6.2 Zugreifen auf Elemente eines `data.frame`

Für `data.frames` gilt genau das gleiche Prinzip. Nur dass wir jetzt zwei Dimensionen berücksichtigen müssen: nämlich die Zeilen und Spalten. Wir können immer noch mit eckigen Klammern (`[]`) auf Elemente innerhalb eines `data.frame` zugreifen, müssen aber jetzt die *Zeile*(*n*) und die *Spalte*(*n*) angeben, die wir haben möchten. Die Schreibweise ist immer `[Zeile(n), Spalte(n)]`. Für Zeilen und Spalten gelten genau die gleichen Regeln wie für Vektoren. Wir können entweder einen Vektor mit den Positionen für die gewünschten Zeilen und Spalten angeben oder einen logischen Vektor, der besagt welche Zeilen und Spalten wir zurückhaben möchten.

Wenn wir z.B. die Anzahl Rehphotos von der vierten Fotofalle abfragen möchten, könnte man das so machen.

```
monitoring[4, 2]
```

```
## [1] 91
```

Alternativ, kann man den Spaltennamen auch einfach Ausschreiben.

```
monitoring[4, "anzahl_rehe"]
```

```
## [1] 91
```

Wenn wir die Anzahl fotografierte Rehe von den ersten fünf Fotofallen abfragen möchten, dann müssen wir für die Zeilen einen Vektor mit den Zahlen 1 bis 5 übergeben, für die Spalten ändert sich nichts.

```
monitoring[1:5, "anzahl_rehe"]
```

```
## [1] 132 79 129 91 138
```

Wenn wir nun nicht nur die Anzahl fotografierte Rehe zurückhaben möchten, sondern auch noch das Revier für die ersten fünf Fotofallen, dann müssen wir für die Spalten lediglich das Revier hinzufügen.

```
monitoring[1:5, c("anzahl_rehe", "revier")]
```

```
##   anzahl_rehe   revier
## 1       132 Revier A
## 2        79 Revier A
## 3       129 Revier A
## 4        91 Revier A
## 5       138 Revier A
```

Wenn wir alle Spalten und/oder Zeilen eines `data.frame` abfragen möchten, dann kann man diese Position einfach frei lassen. Eine Abfrage für die ersten fünf Spalten aller Fotofallen würde so aussehen.

```
monitoring[1:5, ]
```

```
710 ##           ID anzahl_rehe   revier
711 ## 1 Kamera_1         132 Revier A
712 ## 2 Kamera_2          79 Revier A
713 ## 3 Kamera_3         129 Revier A
714 ## 4 Kamera_4          91 Revier A
715 ## 5 Kamera_5         138 Revier A
```

```
716
```

### 717 *Aufgabe 13: Abfragen von Werten*

```
718
```

719 Wir nehmen folgende Werte aus Übung 12 an:

```
umfrage1 <- data.frame(
  fach = c("Forst", "Bio", "Chemie", "Physik", "Forst"),
  semester = c(2, 3, 2, 1, 5),
  alter = c(21, 22, 21, 20, 23)
)
```

- 720 • Wählen Sie nur die ersten drei Zeilen aus und die erste und zweite Spalte aus.
- 721 • Wählen Sie alle Zeilen und die erste und dritte Spalte aus.
- 722 • Wählen Sie alle Spalten und die erste, dritte und vierte Zeile aus.

```
723
```

724 Mit dem `$`-Zeichen kann bei `data.frames` direkt auf Spalten zugegriffen werden. Wenn wir z.B. für alle  
725 Fotofallen die Anzahl gesehener Rehe abfragen möchten, gibt es jetzt drei Möglichkeiten:

726 1. über das `$`-Zeichen direkt die Spalten ansprechen.

```
monitoring$anzahl_rehe
```

```
727 ## [1] 132  79 129  91 138 144  55 103 139 105  96 146  95 118 107
```

728 2. Einfach die Positionen für die Zeilen leer lassen und die Spalte abfragen.

```
monitoring[, "anzahl_rehe"]
```

```
729 ## [1] 132  79 129  91 138 144  55 103 139 105  96 146  95 118 107
```

730 3. Alle Zeilen und die Spalte explizit angeben.

```
monitoring[1:nrow(monitoring), "anzahl_rehe"]
```

```
## [1] 132 79 129 91 138 144 55 103 139 105 96 146 95 118 107
```

Anmerkung zu 3), der Ausdruck `1:nrow(monitoring)` ergibt einen Vektor mit den Zahlen 1 bis 15, da `nrow(monitoring) = 15` ist. So eine Schreibweise ist zu empfehlen, wenn die Dimension des Vektors variabel ist.

Schlussendlich kann man einen `data.frame` auch mit logischen Vektoren abfragen. Ein Beispiel wäre, wenn wir alle Fotofallen abfragen möchten, die mehr als 100 Rehphotos gemacht haben. Der erste Schritt wäre abzufragen, ob eine Fotofalle mehr als 100 Rehphotos gemacht hat.

```
monitoring$anzahl_rehe > 100
```

```
## [1] TRUE FALSE TRUE FALSE TRUE TRUE FALSE TRUE TRUE TRUE FALSE TRUE
```

```
## [13] FALSE TRUE TRUE
```

Das Ergebnis ist ein Vektor mit 15 Elementen. Hat eine Fotofalle mehr als 100 Rehphotos gemacht ist das entsprechende Element des Vektors `TRUE` ansonsten `FALSE`. In dem `data.frame monitoring` steht in jeder Zeile eine Beobachtung (also eine Fotofalle). Nun wollen wir genau diese Fotofallen haben, die mehr als 100 Rehphotos gemacht gemacht haben.

```
monitoring[monitoring$anzahl_rehe > 100, ]
```

```
##           ID anzahl_rehe  revier
## 1 Kamera_1      132 Revier A
## 3 Kamera_3      129 Revier A
## 5 Kamera_5      138 Revier A
## 6 Kamera_6      144 Revier B
## 8 Kamera_8      103 Revier B
## 9 Kamera_9      139 Revier B
## 10 Kamera_10     105 Revier B
## 12 Kamera_12     146 Revier C
## 14 Kamera_14     118 Revier C
## 15 Kamera_15     107 Revier C
```

755

#### Aufgabe 14: Abfragen von Werten 2

Verwenden Sie erneut den Datensatz aus Übung 13 und führen Sie folgende Abfragen durch:

- Alle Spalten für Studierende die Forstwissenschaften studieren.
- Alle Spalten für Studierende die Chemie oder Physik studieren.
- Die Spalte `fach` und `semester` für Studierende die 22 oder älter sind.

## 7 Schreiben und lesen von Daten

### 7.1 Textdateien

Bis jetzt haben wir Daten immer in R erstellt, dies ist eine eher unnatürliche Situation. In den meisten Fällen bekommen Sie Daten von Dritten, Sensoren oder sonstigen Quellen. Diese Daten müssen dann in R eingelesen werden. Daten liegen meist in einer tabellarischen Form und als Textdatei vor<sup>6</sup>.

Die Funktion `read.table` erlaubt es eine Textdatei in R einzulesen. Dabei sind fürs Erste drei Argumente wichtig:

- **file:** Der Pfad zur Datei die eingelesen werden soll. Dieser kann *absolut* oder *relativ* sein. Ein absoluter Pfad gibt den Ort der Datei, die gelesen werden soll, komplett an (auf einem Windows Rechner wäre das wahrscheinlich `C:/Users/...`). Im Gegensatz dazu gibt ein relativer Pfad den Ort an, an dem die Datei, die eingelesen werden soll, relativ zum aktuellen Arbeitsverzeichnis (auch *working directory*) von R an. Man kann das Arbeitsverzeichnis von R mit der Funktion `setwd()` setzen, es hat sich jedoch als sinnvoller erwiesen mit RStudio-Projekten zu arbeiten (mehr dazu im nächsten Abschnitt).
- **header:** Dieses Argument gibt an, ob die erste Zeile eine Kopfzeile mit den Spaltenüberschriften ist. Meist haben wir eine Kopfzeile, dann wäre `header = TRUE` richtig.
- **sep:** Das Trennzeichen zwischen verschiedenen Spalten. Es ist meist ein Leerzeichen (), Komma (`,`) oder Strichpunkt (`;`).

Die Datei `fotofallen.csv` finden Sie auf StudIP und kann einfach heruntergeladen werden. Die Datei kann mit dem folgenden Befehl in R eingelesen werden. Hier wurde die Datei in einem RStudio-Projekt in ein Verzeichnis `data` abgelegt.

```
dat <- read.table("data/fotofallen.csv", header = TRUE, sep = ",")
head(dat)
```

```
##      ID anzahl_rehe   revier
## 1 Kamera_1         132 Revier A
## 2 Kamera_2          79 Revier A
## 3 Kamera_3         129 Revier A
## 4 Kamera_4          91 Revier A
## 5 Kamera_5         138 Revier A
## 6 Kamera_6         144 Revier B
```

Es gibt viele Varianten der Funktion `read.table()`. Beispielsweise hat die Funktion `read.csv()` bereits die Argumente `sep = ','` und `header = TRUE` gesetzt. Die Funktion `read.csv2()` hat das Argument `sep = ';'`  gesetzt. Siehe dazu auch die Hilfeseite von `read.table()`. Diese kann entweder mit `?read.table` oder `help("read.table")` aufgerufen werden.

Mit der Funktion `write.table()` kann ein `data.frame` auf die Festplatte geschrieben werden.

<sup>6</sup>Natürlich gibt es viele weitere Formate wie Daten vorliegen können, diese werden aber an dieser Stelle nicht weiter behandelt. Es sei lediglich auf das Paket `readxl` verwiesen, falls Sie Daten von MS Excel direkt in R einlesen möchten.



794

---

795 ***Aufgabe 15: Lesen und Schreiben von Dateien***  
796

---

797 Lesen Sie die Datei `kompliziert.txt` ein. Schauen Sie die Hilfeseite an und vergewissern Sie sich, dass Sie  
798 wissen was die Argumente `header`, `sep`, `dec` und `skip` bewirken. Setzen die Argumente richtig, damit die  
799 Datei `kompliziert.txt` folgendes Ergebnis liefert.

## 8 Erstellen von Abbildungen

Abbildungen sind ein elementarer Baustein statistischer Analysen und deshalb von Beginn an Teil von R. Es gibt unterschiedliche Systeme einen Plot zu erstellen. In diesem Kurs werden wir kurz *Base Plots* vorstellen und dann das Zusatzpaket `ggplot2` vorstellen.

### 8.1 Base Plot

Die wichtigsten Grafiken für die einfache Datendarstellung sind schnell verfügbar. Etwas komplexere oder spezielle Grafiken erfordern mehr Programmieraufwand (folgt teilweise noch). Stellen sie sich die einfache Grafik Schnittstelle als zweidimensionale Leinwand vor, auf die Sie durch Code Ebene für Ebene Grafikelemente zeichnen:





Abbildung 4: Beispiel einer leeren Grafikschnittstelle.

Hier drei einfache Beispiele für Abbildungen mit nur einer Ebene.

```
dat <- data.frame(
  x = c(0, 1, 2, 2, 3, 5, 6, 7),
  y = c(0, 0.5, 1.8, 0.3, 4, 4, 2, 2.2)
)


plot(dat$x, dat$y, type = "p")
```



810

811 Mit dem Argument `type` kann die Art der Darstellung gesteuert werden. Der Standardwert ist `type = "p"`  
812 (für points). Wir können den selben Plot mit Linien (`type = "l"`)


```
plot(dat$x, dat$y, type = "l")
```



813

814 oder mit Linien und Punkten (`type = "b"` für both)

```
plot(dat$x, dat$y, type = "b")
```



815

816 darstellen.

817

### 818 **Aufgabe 16: Base Plot 1**

819

820 Laden Sie den Datensatz `bhd_1.txt` und erstellen Sie eine Abbildung mit dem Alter jedes Baumes auf der  
 821 x-Achse und dem BHD auf der y-Achse.

822


823 Sie können entweder eine Grafik mit einem Befehl erzeugen (High-Level) oder die einzelnen Ebenen nach-  
 824 einander erzeugen (Low-Level). Sie können jeder Ebenen durch zusätzliche Befehle innerhalb des Funktions-  
 825 aufrufs Elemente hinzufügen und Einstellungen ändern. Die wichtigsten sind:

- 826 • `type` - Diagrammtyp
- 827 • `col` - Farbe
- 828 • `main` - Titel
- 829 • `sub` - Untertitel
- 830 • `pch` - Punktsymbol
- 831 • `lty` - Linientyp
- 832 • `lwd` - Linienstärke

- `xlab` bzw. `ylab` - Achsenbeschriftungen
- `xlim`, `ylim` - Grenzen der Achsenanschnitte
- `axes` - Sollen die Achsen eingezeichnet werden? Oder leer gelassen werden, um sie nachträglich als low-level Ebene einzuzichnen?
- `ann` - Achsenbeschriftung kann ganz weggelassen werden.

Sehen Sie sich die Hilfeseiten `?plot.default()` oder `?par()` an für weitere Informationen. Dort finden Sie auch eine vollständige Liste der Befehle. Einige Argumente können als Vektor übergeben werden. Hier z. B. die Farben und die Punktsymbole.

```
plot(1:20, 1:20, pch = c(1 : 20), col = c(1 : 20), ann = FALSE)
```



### Aufgabe 17: Anpassen von Plots

Verwenden Sie den Datensatz aus Übung 16 und passen Sie die Abbildung wie folgt an:

- Beschriften Sie die x- und y-Achse sinnvoll.
- Fügen Sie eine Überschrift hinzu.
- Wählen Sie ein anderes Symbol.
- Stellen Sie die Symbole in rot dar.

Über Low-Level Funktionen können einer Grafik Schnittstelle nacheinander Elemente hinzugefügt werden. Die wichtigsten Funktionen sind

- `points()` - Fügt Punkte ein
- `lines()` - Fügt Linien ein
- `text()` - Fügt Text ein
- `legend()` - Fügt eine Legende ein
- `abline()` - Fügt eine Gerade ein
- `curve()` - Fügt eine mathematische Funktion ein
- `arrows()` - Fügt Pfeile ein
- `grid()` - Fügt Hilfslinien ein

Dabei ist der Aufbau zunächst grundsätzlich wie in Abbildung 5 dargestellt. Der Vorteil von Low-Level Funktionen ist, dass die einzelnen Level mehr Funktionen bieten als die High-Level Funktion und, dass Sie sich die Reihenfolge der Ebenen definieren können.




Abbildung 5: Grafikregionen eines base plots in R.

Mit diesem grundsätzlichen Aufbau sollten Sie bereits in der Lage sein auch komplexe Grafiken schnell zu gestalten. Wenn Sie mehrere Diagramme in einem Plot arrangieren möchten, können Sie mit dem `par()`

866 Befehl ein Arrangement definieren. Sie haben dann zusätzlich zu den bereits bekannten Grafikregionen noch  
 867 äußere Ränder (*outer margins*). Siehe Abbildung 6.

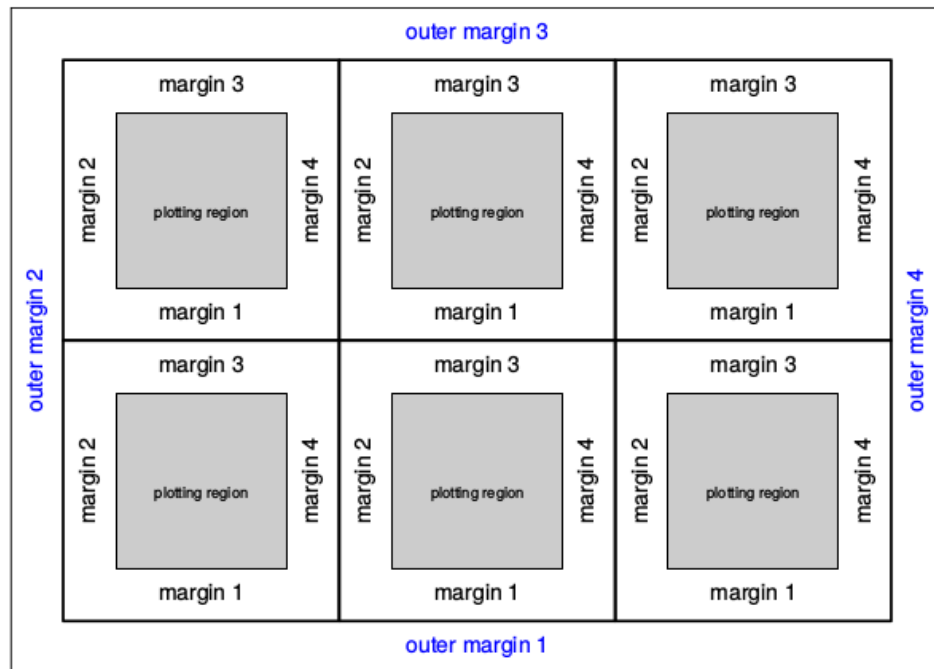


Abbildung 6: Schematischer Aufbau mehrere Diagramme in einem plot am Beispiel einer 3 x 2 Grafik.


### 8.1.1 Mehrere Panels

869 Mit der Funktion `par()` kann auch eingestellt werden, dass ein Plot aus mehreren Subplots (= Panels)  
 870 besteht. Die Argumente `mfrow` und `mfcol` können `par()` übergeben werden und kontrollieren die Anzahl  
 871 Zeilen und Spalten für den Plot.

```
par(mfrow = c(1, 3))
```

872 Teilt den Plot in eine Zeile und drei Zeilen (= drei Plots nebeneinander).

```
# Erstes Panel
plot(bhd ~ alter, xlab = "Alter", ylab = "BHD", pch = 20, col = "red",
     data = dat[dat$gebiet == "A", ], main = "Gebiet A")
# Zweites Panel
plot(bhd ~ alter, xlab = "Alter", ylab = "BHD", pch = 20, col = "red",
     data = dat[dat$gebiet == "B", ], main = "Gebiet B")
# Drittes Panel
plot(bhd ~ alter, xlab = "Alter", ylab = "BHD", pch = 20, col = "red",
     data = dat[dat$gebiet == "C", ], main = "Gebiet C")
```



873

874 Vergessen Sie nicht am Ende nochmals `par(mfrow = c(1, 1))` zu setzen, damit wieder nur ein Plot ange-  
 875 zeigt wird.

### 876 8.1.2 Speichern von Abbildungen

877 Wenn nicht anders angegeben, wird die Abbildung zunächst nur in der RStudio Grafik Schnittstelle abgebildet  
 878 (rechts unten). Von dort aus kann die Abbildung exportiert werden. Es bietet sich jedoch an das Speichern  
 879 der Abbildung direkt im Code zu programmieren. Mögliche Formate die Abbildung als Vektorgrafik zu  
 880 speichern sind

- 881 • `pdf()` oder
- 882 • `postscript()`.

883 Beispiele für Rastergrafiken sind

- 884 • `png()`,
- 885 • `bmp()` oder
- 886 • `jpeg()`.

887 Die Grafikschnittstelle ist dann Ihre “Leinwand”. Mit dem Befehl `dev.off()` trennen Sie die Verbindung  
 888 zur Schnittstelle wieder. Ihre “Leinwand” wird also wieder geschlossen. So lange die Schnittstelle geöffnet ist  
 889 werden alle Low-Level Befehle an die Ausgabedatei gesendet. Hier am Beispiel einer PDF.




```
pdf("Grafik.pdf", height = 5)           # Öffnen der PDF Schnittstelle
plot(bhd ~ alter, type = "b", axes = FALSE, # Abbildung produzieren, Ohne Achsen
     data = dat)
axis(side = 1, line = 1)                 # Achsen als High-Level Funktion hinzufügen
axis(side = 2, line = 1, las = 2)        # Sehen Sie selbst in der Hilfe was las bedeutet
dev.off()                                # Schnittstelle schließen
```

890 Achtung, wenn Sie die Funktion `dev.off()` nicht aufrufen, werden alle nachfolgenden Plots in die gleiche  
 891 Datei geschrieben. Falls Sie nach einem Versuch einen Plot zu speichern plötzlich keine weiteren Plots mehr  
 892 sehen, führen Sie einige Mal die Funktion `dev.off()` aus.

## 893 8.2 Histogramme

894 Neben den Streudiagrammen (*Scatterplots*, oder auch einfach x-y Diagramm) sind *Histogramme* in der  
 895 angewandten Datenanalyse ein weiterer wichtiger Abbildungstyp. An Histogrammen wird die Häufigkeit  
 896 von Beobachtungen nach Gruppen dargestellt. Sie sind deshalb so wichtig, weil man aus ihnen relevante  
 897 Informationen über die Verteilung der Daten ablesen kann. So werden auf einen Blick der Zusammenhang  
 898 von Beobachtungshäufigkeit und Streuung deutlich, sowie auch die Form der Verteilung und ihre Schiefe.  
 899 Die Interpretation werden wir bei den Boxlots noch weiter vertiefen.


```
datHistogramm <- read.table("data/bhd_1.txt", header = TRUE)
# Über alle Baumarten
hist(datHistogramm$bhd)
```



900

```
# Nur für Eichen, Standardeinstellungen
hist(datHistogramm$bhd[datHistogramm$art == "EI"])
```

Histogram of datHistogramm\$bhd[datHistogramm\$art == "EI"]

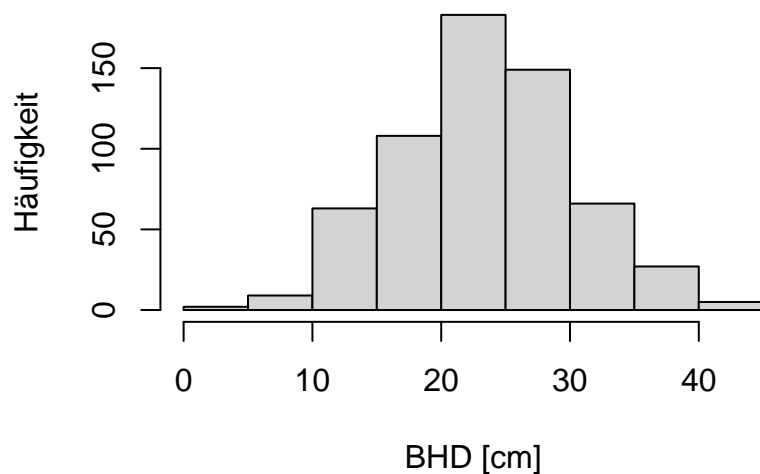


datHistogramm\$bhd[datHistogramm\$art == "EI"]

901

```
# Nur für Eichen, geänderte High-Level Einstellungen
hist(datHistogramm$bhd[datHistogramm$art == "EI"],
      xlab = "BHD [cm]", ylab = "Häufigkeit",
      main = "Anzahl der Eichen")
```

Anzahl der Eichen




902

903 Eichen und Buchen im 2x1 Plot nebeneinander.

```
par(mfrow = c(1, 2))
hist(datHistogramm$bhd[datHistogramm$art == "EI"],
     xlab = "BHD [cm]", ylab = "Häufigkeit",
     main = "Eiche")
hist(datHistogramm$bhd[datHistogramm$art == "BU"],
     xlab = "BHD [cm]", ylab = "Häufigkeit",
     main = "Buche")
```

904



905

```
par(mfrow = c(1, 1)) # Alte Grafikeinstellungen wiederherstellen
```

## 906 8.3 Boxplots

907 Oft möchte man die Verteilung einer stetigen Variablen in Abhängigkeit einer diskreten Variable beschreiben  
 908 oder Visualisieren. Ein Beispiel dafür wäre die BHD-Verteilung für unterschiedliche Baumarten. Eine häufige  
 909 Darstellungsform für solche Daten sind *Boxplots*.

910 Boxplots bestehen aus drei Komponenten:

- 911 1. Eine *Box*, die den Bereich zwischen 0.25 und 0.75 Perzentil abdeckt, diese Distanz wird auch die IQR  
 912 (Interquartile Range), bezeichnet. Zusätzlich wird die Box durch den Median (als dicke horizontale Linie)  
 913 unterteilt.
- 914 2. Einzelne Punkte Ausreißer. Als Ausreißer werden Punkte bezeichnet, die  $> 1.5IQR$  vom unteren oder  
 915 oberen Ende der Box entfernt sind.

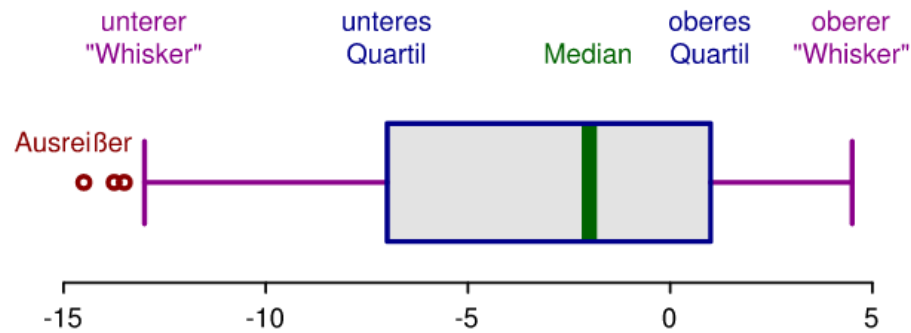



Abbildung 7: Schematische Darstellung eines Boxplots (Quelle: Von RobSeb - Eigenes Werk, CC BY-SA 3.0, <https://commons.wikimedia.org/w/index.php?curid=14697172>).

3. Eine senkrechte Linie von jeder Seite der Box bis zum letzten "Nicht-Ausreißer-Punkt". Diese Linie wird auch oft als *Whisker* bezeichnet.

Mit R kann mit der Funktion `boxplot()` ein Boxplot erstellt werden. Diese Funktion kann in zwei unterschiedlichen Ausprägungen verwendet werden.


1. `boxplot(x)` erzeugt einen Boxplot für die Variable `x`.
2. `boxplot(x ~ y)` erzeugt einen oder mehrere Boxplots für `x` aber gruppiert nach `y`, dabei sollte `y` eine kategoriale Variable sein. `x` und `y` können auch die Spaltennamen eines `data.frame` sein, dann muss das `data.frame` mit dem Argument `data` zusätzlich übergeben werden.

```
boxplot(iris$Sepal.Length ~ iris$Species)
```



Etwas eleganter ist es wenn wir das Argument `data` verwenden und den Plot etwas anpassen.

```
boxplot(
  Sepal.Length ~ Species, data = iris, ylab = NULL, xlab = "Kelchblattlänge [cm]",
  horizontal = TRUE, las = 1, cex.axis = 0.8
)
```





### Aufgabe 18: Boxplots

- Lesen Sie erneut den Datensatz `daten/bhd_1.txt` ein und speichern Sie diesen in die Variable `(dat_bhd)`.
- Wie viele BHD-Messungen gibt es für jedes Gebiet?
- Erstellen Sie für jedes Gebiet einen Plot

Erstellen Sie einen Plot mit 3 Subplots, jeweils mit einem Boxplot für die ersten drei Studiengebiete, in dem der BHD für jede Baumart dargestellt wird.

## 8.4 `ggplot2`: Eine Alternative für Abbildungen

`ggplot2` ist ein alternatives Plotting-System in *R*. Sie können mit `ggplot2` also grundsätzlich Abbildungen mit dem selben Inhalt erstellen wie mit Base Plots. Die Syntax und die optische Darstellung unterscheiden sich jedoch grundsätzlich. `ggplot2` basiert auf den *grammar of graphics* von Leland Wilkinson. Die Idee ist, alle nötigen Informationen der Abbildung miteinander zu verknüpfen. `ggplot2` ist also diametral zu Base

Plots. Mit diesen gebündelten Informationen kann **ggplot2** die Abbildung automatisch verschönern. So werden bspw. die Legenden automatisch erzeugt und auch die Formatierungen automatisch an die Datenlage angepasst. **ggplot2** nimmt der\*dem Entwickler\*in also Arbeit ab. Dadurch sind die Abbildungen schon ohne viel Nacharbeit schick. Nachteil ist, dass der\*dem Entwickler\*in weniger Möglichkeiten zur Einstellung zur Verfügung stehen und nuterspezifische Sonderwünsche somit schwerer umsetzbar sind. Sehen Sie sich das *Cheatsheet* zu **ggplot2** an. Es ist in RStudio unter   zu finden.

Bei **ggplot2** sind Anweisungen zu den Daten und Anweisungen zur Darstellung voneinander getrennt. Die Daten werden in den Ästhetikbefehl übergeben und dort klassifiziert. Dann folgen die Darstellungsanweisungen. Ähnlich wie bei Base Plots werden die Grafikelemente ebenenweise nacheinander programmiert, jedoch mit einem **+** verbunden. Und hier liegt der wesentliche Unterschied zu Base Plots. Durch die **+** werden die Ebenen zu einem Befehl verbunden und damit gleichzeitig erstellt.

Die Erweiterung wird zunächst geladen<sup>7</sup>. Falls nicht schon geschehen, muss sie vorher installiert werden. Wir laden außerdem den Datensatz **iris**. Der Datensatz ist in R fest integriert. Siehe **?iris** für mehr Informationen.


```
library(ggplot2)
head(iris)
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1          3.5          1.4          0.2 setosa
## 2          4.9          3.0          1.4          0.2 setosa
## 3          4.7          3.2          1.3          0.2 setosa
## 4          4.6          3.1          1.5          0.2 setosa
## 5          5.0          3.6          1.4          0.2 setosa
## 6          5.4          3.9          1.7          0.4 setosa
```

Die Ästhetik wird bspw. folgendermaßen definiert.

```
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width))
```


<sup>7</sup>Wir haben bis jetzt immer nur mit *base* R gearbeitet. D.h. wir haben nur Funktionen verwendet, die R bereits zur Verfügung stellt. Eine der großen Stärken von R sind die Erweiterungen (oder auch Pakete genannt). **ggplot2** ist so eine Erweiterung, die einmal mit **install.packages("ggplot2")** installiert werden muss. Danach muss man das Paket am Anfang jeder Session mit **library(ggplot2)** laden, damit die Funktionen aus dem Paket zur Verfügung stehen.



963

964 Dieser Befehl zeichnet noch keine Daten. Die Daten werden lediglich herangezogen, um einen leeren Plot für  
965 die Daten zu erstellen. In dem Beispiel wird die Variable `Sepal.Length` aus dem `data.frame iris` als x und  
966 `Sepal.Width` als y Variable definiert. Diese Informationen stehen den folgenden Layern nun zur Verfügung,  
967 sodass nach den `+` nur noch x und y verwendet werden müssen. Um bspw. einen Scatterplot zu erstellen  
968 wird ein `geom_point()` Layer hinzugefügt. x und y werden automatisch an `geom_point` übergeben. Weitere  
969 Einstellung sind in diesem Beispiel nicht notwendig, wären jedoch möglich. Siehe `?geom_point()`.

```
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width)) + geom_point()
```



970

971

---

972 **Aufgabe 19: Abbildungen mit ggplot2**

---

973

974 Verwenden Sie die Daten aus Aufgabe 16 und erstellen Sie einen Scatterplot mit **ggplot2** wie in Aufgabe 16.

975

976 Wir haben mit der Funktion **geom\_point()** dem Plot eine Punktgeometrie hinzugefügt. Es gibt noch viele  
977 weitere Geometrien. Die wichtigsten sind:

- 978 • **geom\_line()** für eine Linie.
- 979 • **geom\_histogram()** um ein Histogramm zu erstellen.
- 980 • **geom\_boxplot()** um einen Boxplot zu erstellen.
- 981 • **geom\_bar()** um ein Säulendiagramm zu erstellen.

982 Welche Geometrie die richtige ist, richtet nach dem Typ der darzustellenden Variablen. Beispielsweise bie-  
983 tet sich **geom\_point()** an, wenn man zwei kontinuierliche Variable darstellen möchte. Wenn man hinge-  
984 gen die Verteilung von einer kontinuierlichen Variable darstellen möchte, dann bietet sich ein Histogramm  
985 (**geom\_histogram()**) oder auch eine geschätzte Dichte (z.B. **geom\_density()**) an.

986

---

987 **Aufgabe 20: Abbildungen mit ggplot2**

---

988


989 Verwenden Sie den Iris Datensatz und erstellen Sie mit **ggplot2** einen Plot der die Verteilung der Länge  
990 der Kelchblätter zeigt (Spalte **Sepal.Length**).

991

992 Eine der Stärken von **ggplot2** ist, dass man den Wert unterschiedlicher Variable auf unterschiedlichen  
993 Komponenten des Plots abbilden kann. Wir haben bis jetzt ein bzw. zwei Variable auf der x- und y-Achse  
994 abgebildet. Wir können aber eine weitere Variablen verwenden um das Aussehen des Plots zu beeinflussen.  
995 Beispielsweise können wir die Farbe der Punkte (für **geom\_point()**) mit dem Argument **col** beeinflussen.

```
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width, col = Species)) +  
  geom_point()
```






996

997 Somit bekommt jede Irisart eine eigene Farbe<sup>8</sup>. Gleichmaßen können wir die Punktart (`shape`), die Punkt-  
 998 gröÙe (`size`) etc. anpassen.

```
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width,
                 col = Species, shape = Species)) +
  geom_point()
```




999

<sup>8</sup>Natürlich könnte man auch die Farbe anpassen.

In dem Plot ist die Information zu der Art redundant (einmal als Farbe und einmal Symbolart).


Ein weitere sehr nützliche Geometrie ist `geom_smooth()`, die es erlaubt eine Trendlinie hinzuzufügen.

```
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width)) +  
  geom_point() + geom_smooth(method = "lm")
```



Mit `method = "lm"` wird festgelegt, dass die Trendlinie gerade sein soll (es wird eine lineare Einfachregression angepasst). Wenn wird wieder eine gruppierende Variable einführen (z.B. die Beobachtungen nach Art auf die Farbe aufteilen), wird das von `geom_smooth()` berücksichtigt.

```
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width, col = Species)) +  
  geom_point() + geom_smooth(method = "lm")
```




### Aufgabe 21: Anpassen von Plots

Lesen Sie den Datensatz `data/bhd_1.txt` ein und erstellen Sie einen Boxplot für die Verteilung des BHDs für jede Baumart. In einem zweiten Schritt verwenden Sie erst `col = gebiet` und dann `fill = gebiet`. Welchen Unterschied stellen Sie fest?

```
dat <- read.table("data/bhd_1.txt", header = TRUE)
head(dat)
ggplot(dat, aes(art, bhd, fill = gebiet)) + geom_boxplot()
```

Mit der Funktion `labs()` werden die Beschriftungen geändert.

```
ggplot(iris, aes(x = Sepal.Width, y = Sepal.Length, color = Species)) +
  geom_point() + geom_smooth(method = "lm") +
  labs(x = "Kelchblattbreite [mm]", y = "Kelchblattlänge [mm]",
       title = "Kelchblätter", color = "Irisart")
```




1015

1016 Statt einen langen Befehl zu tippen, kann ein `ggplot()` auch zwischengespeichert und wieder aufgerufen bzw.  
 1017 angepasst werden. Das ist vor allem sinnvoll, wenn mehrere Abbildungen auf dem selben Zwischenergebnis  
 1018 aufbauen sollen.

```
p1 <- ggplot(iris, aes(x = Sepal.Width, y = Sepal.Length, color = Species)) +  
  geom_point() + geom_smooth(method = "lm")
```

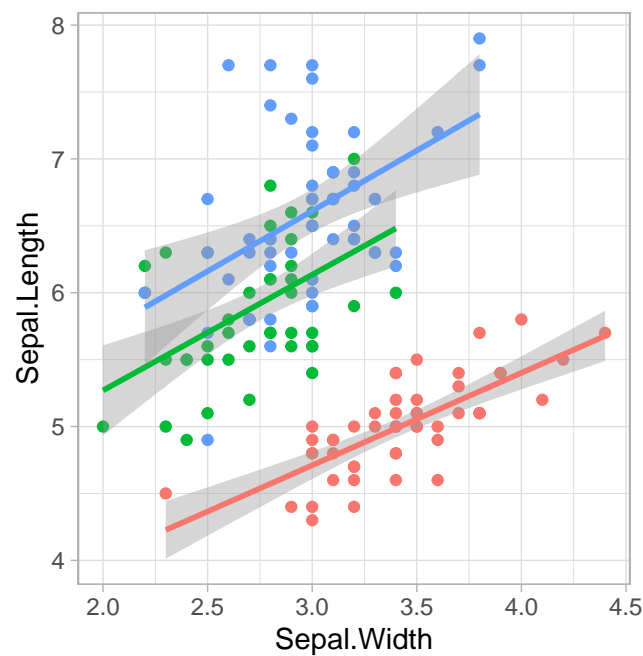
1019 Wir können jetzt mit `p1` weiter arbeiten und beispielsweise eine Beschriftung hinzufügen.

```
p1 + labs(x = "Kelchblattbreite [mm]", y = "Kelchblattlänge [mm]")
```



Oder auch den ganzen Plot anpassen. Dafür gibt es *themes*. Es gibt eine Reihe von vorgefertigten *themes* oder man kann diese auch selber erstellen (das ist aber nicht Teil dieses Kurses).

```
p1 + theme_light()
```




Weitere *themes* sind: `theme_bw()`, `theme_linedraw()` oder `theme_dark()`. Es gibt extra Pakete die viele zusätzliche weitere *themes* an bieten. Dazu gehört z.B. das Paket `ggthemes`.

### 8.4.1 Multipanel Abbildungen

Mit `ggplot2` kann man einfach Abbildungen erstellen, die mehrere Panels haben. Das bedeutet, dass eine oder mehrere weitere Variablen gibt, die einen Plot in mehrere Subplots teilt. Dafür gibt es zwei Funktionen: `facet_grid()` und `facet_wrap()`.


```
ggplot(iris, aes(Sepal.Length)) + geom_histogram() +  
  facet_grid(~ Species)
```



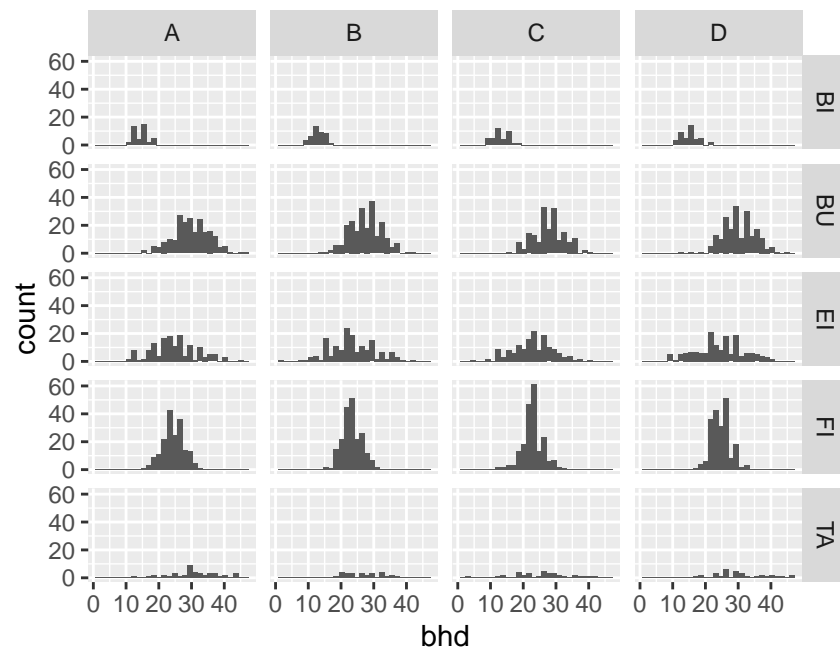
Die Funktion `facet_grid()` erzeugt einen *Grid*, während `facet_wrap()` für jedes Panel eine eigene Überschrift erzeugt.

### Aufgabe 22: Multipanel Abbildungen

Lesen Sie erneut den Datensatz `daten/bhd_1.txt` ein und speichern Sie diesen in die Variable (`dat_bhd`). Erstellen Sie für jede Art und Gebiet ein Histogramm. Welche Unterschiede können Sie feststellen, wenn Sie `facet_grid()` oder `facet_wrap()` verwenden?



1039



1040

#### 1041 8.4.2 Plots kombinieren

1042 Es gibt Situationen in denen **unterschiedliche** Plots miteinander kombiniert werden müssen. Im vorherigen  
 1043 Abschnitt wurde dies immer anhand einer gruppierenden Kovariate gemacht. Aber es gibt auch Situatio-  
 1044 nen, in denen das nicht möglich ist. Beispielsweise wenn ein Histogramm und ein Scatterplot vom gleichen  
 1045 Datensatz zusammengefasst werden sollen. Dafür bietet sich das Paket **patchwork** an<sup>9</sup>.


<sup>9</sup>Auch dieses Paket müssen Sie einmalig mit `install.packages("patchwork")` installieren.

1046 Als erstes können wir zwei (oder natürlich auch mehrere Plots) erstellen. Hier unterscheiden sich die Plots  
 1047 lediglich durch das Aussehen.

```
p1 <- ggplot(iris, aes(Sepal.Width)) + geom_histogram()
p2 <- p1 + theme_light()
```

1048 Dann müssen können wir diese Plots ebenfalls mit + zusammenfügen.

```
library(patchwork)
p1 + p2
```




1049

1050 Natürlich können auch weitere Plots hinzugefügt werden (auch in unterschiedlichen Dimensionen):

```
(p1 + p2) / p2
```






1051

1052 Des weiteren können mit `|` auch Plots gegenüber gestellt werden.

```
(p1 + p2) | p2
```




1053

1054 Weitere Optionen können mit `plot_layout()` und `plot_annotation()` angepasst werden. Mit  
 1055 `plot_layout()` kann die Anordnung der Plots bestimmt werden (z.B. über die Argument `nrow` und  
 1056 `ncol`), sowie deren *relative* Größe (über die Argumente `widths` und `heights`). Mit der Funktion

1057 `plot_annotation()` können zusätzliche Beschriftungen hinzugefügt werden, wie beispielsweise eine Titel  
 1058 (Argument `title`) oder ein Buchstabe/Zahl für jedes Element (Argument `tag_levels`).

```
p1 + p2 +  
  plot_layout(ncol = 1, heights = c(0.3, 0.7)) +  
  plot_annotation(title = "Zwei Histogramme", tag_levels = "A")
```

### Zwei Histogramme




1059

1060

### 1061 *Aufgabe 23: Mehrere Plots zusammenfügen*

1062

1063 Versuchen Sie die folgende Zusammenstellung der Plots nachzumachen:



1064

### 1065 8.4.3 Speichern von plots

1066 Sie können mit `ggsave()` eine zwischen-gespeicherte Abbildung exportieren, indem Sie den Variablennamen  
 1067 übergeben. Wenn Sie keine Variable übergeben, wird automatisch die letzte Abbildung gespeichert. Das  
 1068 Dateiformat wird aus dem Dateinamen übernommen.

```
ggsave("letzteAbb.png")
ggsave(p1, "zwischenengespeicherteAbb.png")
```

## 9 Mit Daten arbeiten

### 9.1 dplyr eine Einführung

`dplyr` ist eine Erweiterung von R (= Paket), die das Ziel hat den Umgang mit Daten einfacher und schneller zu machen.

`dplyr` definiert 5 Verben, um mit Daten zu arbeiten. Diese sind:

- `filter`
- `select`
- `arrange`
- `mutate`
- `summarise`

```
dat <- data.frame(id = 1:5,
                  plot = c(1, 1, 2, 2, 3),
                  bhd = c(50, 29, 13, 23, 25),
                  alter = c(10, 30, 31, 24, 25))
```

Damit die Funktionen aus `dplyr` verwendet werden können, müssen wir als erstes das Paket `dplyr` laden.

```
library(dplyr)
```

Sollte dies zu einer Fehlermeldung führen, dann müssen Sie das Paket `dplyr` erst installieren. Dafür müssen Sie **einmalig** `install.packages("dplyr")` installieren.

`dplyr` stellt unterschiedliche Funktionen zum Arbeiten mit Daten zur Verfügung. Es gibt fünf Grundfunktionen für die am häufigsten vorkommenden Operationen. Mit der Funktion `filter()` können unterschiedliche Beobachtungen gefiltert werden:

```
filter(dat, bhd > 10)
```

```
##   id plot bhd alter
## 1  1    1  50    10
## 2  2    1  29    30
## 3  3    2  13    31
## 4  4    2  23    24
## 5  5    3  25    25
```

Es können auch mehrere Spalten verwendet werden.

```
filter(dat, bhd > 10, bhd < 40)
```

```
1092 ##   id plot bhd alter
1093 ## 1  2    1  29    30
1094 ## 2  3    2  13    31
1095 ## 3  4    2  23    24
1096 ## 4  5    3  25    25
```

1097 Natürlich kann genau das gleiche Ergebnis mit dem ‘normalen’ R erreicht werden, dies wäre dann:

```
dat[dat$bhd > 10 & dat$bhd < 40, ]
```

```
1098 ##   id plot bhd alter
1099 ## 2  2    1  29    30
1100 ## 3  3    2  13    31
1101 ## 4  4    2  23    24
1102 ## 5  5    3  25    25
```

1103 Eine weitere Funktion aus dem Paket dplyr ist `select()`. Damit können Spalten aus einem `data.frame`  
1104 ausgewählt werden. Dabei können auch die Spaltennamen unbenannt werden.

```
select(dat, bhd)
```

```
1105 ##   bhd
1106 ## 1  50
1107 ## 2  29
1108 ## 3  13
1109 ## 4  23
1110 ## 5  25
```

```
select(dat, bhd, id)
```

```
1111 ##   bhd id
1112 ## 1  50  1
1113 ## 2  29  2
1114 ## 3  13  3
1115 ## 4  23  4
1116 ## 5  25  5
```

```
select(dat, BHD = bhd, id)
```

```

1117 ##   BHD id
1118 ## 1  50  1
1119 ## 2  29  2
1120 ## 3  13  3
1121 ## 4  23  4
1122 ## 5  25  5

```

1123 Mit der Funktion `arrange()` können die Beobachtungen in einem `data.frame` sortiert werden.

```
arrange(dat, bhd)
```

```

1124 ##   id plot bhd alter
1125 ## 1  3    2  13    31
1126 ## 2  4    2  23    24
1127 ## 3  5    3  25    25
1128 ## 4  2    1  29    30
1129 ## 5  1    1  50    10

```

1130 Mit der Funktion `desc()` kann die Anordnung in absteigender Reihenfolge sortiert werden.

```
arrange(dat, desc(bhd))
```

```

1131 ##   id plot bhd alter
1132 ## 1  1    1  50    10
1133 ## 2  2    1  29    30
1134 ## 3  5    3  25    25
1135 ## 4  4    2  23    24
1136 ## 5  3    2  13    31

```

1137 Mit der Funktion `mutate()` kann man eine neue Spalte hinzufügen.

```
mutate(dat, bhd_mm = bhd * 10, fl = pi * (bhd/2)^2)
```

```

1138 ##   id plot bhd alter bhd_mm      fl
1139 ## 1  1    1  50    10     500 1963.4954
1140 ## 2  2    1  29    30     290 660.5199
1141 ## 3  3    2  13    31     130 132.7323
1142 ## 4  4    2  23    24     230 415.4756
1143 ## 5  5    3  25    25     250 490.8739

```

```
mutate(dat, mean_bhd = mean(bhd))
```

```

1144 ##    id plot bhd alter mean_bhd
1145 ## 1  1    1  50    10        28
1146 ## 2  2    1  29    30        28
1147 ## 3  3    2  13    31        28
1148 ## 4  4    2  23    24        28
1149 ## 5  5    3  25    25        28

```

1150 Mit der Funktion `summarise()` können Spalten zusammengefasst werden.

```

summarise(
  dat,
  mean_bhd = mean(bhd),
  mean_sd = sd(bhd)
)

```

```

1151 ##    mean_bhd mean_sd
1152 ## 1         28 13.63818

```

1153

### 1154 *Aufgabe 24: Datenmanipulation mit dplyr*

1155

- 1156 1. Laden Sie den Datensatz `data/bhd_1.txt`
- 1157 2. Berechnen Sie folgende Werte für alle Einträge und speichern Sie die Ergebnisse in `erg1`
  - 1158 • mittlerer `bhd`
  - 1159 • maximales `alter`
  - 1160 • die Standardabweichung des BHDs
  - 1161 • die Anzahl Bäume mit einem BHD > 30

## 1162 9.2 Arbeiten mit gruppierten Daten

1163 Zusätzlich können `mutate` und `summarise` auch auf gruppierte Daten angewendet werden. Dafür müssen  
 1164 wir erst die Funktion `group_by()` aufrufen und als Argumente die Variablen übergeben, die die Gruppen  
 1165 definieren.

```

dat1 <- group_by(dat, plot)
mutate(dat, bhd_m = mean(bhd)) # bhd über alle Bäume

```

```

1166 ##    id plot bhd alter bhd_m
1167 ## 1  1    1  50    10    28
1168 ## 2  2    1  29    30    28

```

```

1169 ## 3 3 2 13 31 28
1170 ## 4 4 2 23 24 28
1171 ## 5 5 3 25 25 28

```

```
mutate(dat1, bhd_m = mean(bhd)) # bhd pro Plot
```

```

1172 ## # A tibble: 5 x 5
1173 ## # Groups:   plot [3]
1174 ##      id plot  bhd alter bhd_m
1175 ##   <int> <dbl> <dbl> <dbl> <dbl>
1176 ## 1     1     1     50     10 39.5
1177 ## 2     2     1     29     30 39.5
1178 ## 3     3     2     13     31 18
1179 ## 4     4     2     23     24 18
1180 ## 5     5     3     25     25 25

```

```
summarise(dat, bhd_m = mean(bhd))
```

```

1181 ##   bhd_m
1182 ## 1    28

```

```
summarise(dat1, bhd_m = mean(bhd))
```

```

1183 ## # A tibble: 3 x 2
1184 ##   plot bhd_m
1185 ##   <dbl> <dbl>
1186 ## 1     1 39.5
1187 ## 2     2 18
1188 ## 3     3 25

```

```
1189
```

```

1190 Aufgabe 25: dplyr mit gruppierten Daten
1191

```

---

- ```

1192 1. Laden Sie den Datensatz data/bhd_1.txt
1193 2. Berechnen Sie für jede Baumart und Standort die folgenden Werte:

```

- ```

1194 • mittlerer bhd
1195 • maximales alter
1196 • die Standardabweichung des BHDs
1197 • die Anzahl Bäume mit einem BHD > 30

```

- ```

1198 3. Ordnen Sie das Ergebnis nach Baumart und BHD.

```



### 9.3 pipes oder %>%

Mit *Pipes* (%>%) kann man das Ergebnis einer Funktion einfach an eine nachfolgende Funktion weiterreichen.

```
a <- c(5, 3, 2, NA)
```

Wir kennen bis jetzt:

```
mean(na.omit(a))
```

```
## [1] 3.333333
```

Mit *Pipes*, die durch das Symbol %>% dargestellt werden<sup>10</sup>, können wir das etwas vereinfachen und nacheinander schreiben:

```
na.omit(a) %>% mean
```

```
## [1] 3.333333
```

Oder sogar

```
a %>% na.omit %>% mean
```

```
## [1] 3.333333
```

#### Aufgabe 26: Pipes %>%

Wiederholen Sie die letzte Aufgabe, aber diesmal ohne Zwischenergebnisse zu speichern:

1. Laden Sie den Datensatz `data/bhd_1.txt`.
2. Berechnen Sie für jede Baumart und Standort die folgenden Werte:
  - mittlerer `bhd`
  - maximales `alter`
  - die Standardabweichung des BHDs
  - die Anzahl Bäume mit einem BHD > 30
3. Ordnen Sie das Ergebnis nach Baumart und BHD.

<sup>10</sup>In RStudio kann %>% mit der Tastenkombination `Strg + Umschalt + m` (`(Strg) + (↑) + (m)`) eingefügt werden.

## 9.4 Joins

Eine weitere häufige Aufgabe beim Daten Management ist es Daten zusammenzuführen. Nehmen Sie an, dass wir folgende Aufnahmen gemacht haben

```
aufnahmen <- data.frame(
  id = 1:3,
  bhd = c(20, 31, 74)
)
```

und jeder Baum lediglich mit einer `id` versehen wurde. In einer zweiten Tabelle wurden dann weitere Daten zu Bäumen gespeichert (z.B. die Art, das Studiengebiet usw).

```
metadaten <- data.frame(
  id = 2:4,
  art = c("Ta", "Bu", "Bu"),
  gebiet = c("A", "B", "B")
)
```

Ziel ist es jetzt die Bäume aus `aufnahmen` mit den Informationen aus den `metadaten` zu verbinden. Dazu dient `id` als Bindeglied (oft auch Schlüssel genannt).

Dazu gibt es vier Möglichkeiten.




Abbildung 8: Joins (Quelle Rstudio)

Zur Durchführung gibt es in base R die Funktion `merge()`. Wir werden aber gleich die Funktionen aus dem Paket `dplyr` verwenden.

```
library(dplyr)
left_join(aufnahmen, metadaten, by = "id")
```

```
1229 ##   id bhd  art gebiet
1230 ## 1  1  20 <NA>   <NA>
1231 ## 2  2  31   Ta     A
1232 ## 3  3  74   Bu     B
```

```
right_join(aufnahmen, metadaten, by = "id")
```

```
1233 ##   id bhd art gebiet
1234 ## 1  2  31 Ta     A
1235 ## 2  3  74 Bu     B
1236 ## 3  4  NA Bu     B
```

```
inner_join(aufnahmen, metadaten, by = "id")
```

```
1237 ##   id bhd art gebiet
1238 ## 1  2  31 Ta     A
1239 ## 2  3  74 Bu     B
```

```
full_join(aufnahmen, metadaten, by = "id")
```

```
1240 ##   id bhd  art gebiet
1241 ## 1  1  20 <NA>   <NA>
1242 ## 2  2  31   Ta     A
1243 ## 3  3  74   Bu     B
1244 ## 4  4  NA   Bu     B
```

1245 by kann auch unterschiedliche Spalten in den beiden `data.frames` ansprechen:

```
metadaten <- data.frame(
  baum_id = 2:4,
  art = c("Ta", "Bu", "Bu"),
  gebiet = c("A", "B", "B")
)
```

```
left_join(aufnahmen, metadaten, by = c("id" = "baum_id"))
```

```
1246 ##   id bhd  art gebiet
1247 ## 1  1  20 <NA>   <NA>
1248 ## 2  2  31   Ta     A
1249 ## 3  3  74   Bu     B
```

**Aufgabe 27: Verbinden von Daten**

- Lesen Sie die Datensätze `daten/bhd_2.txt` und `daten/bhd_2_meta.txt` ein.
- Stellen Sie sicher, dass es für den `bhd` keine fehlenden Werte gibt (entfernen sie entsprechende Zeilen)
- Fügen Sie zu den Metadaten (gespeichert in `bhd_2_meta`) die Anzahl Bäume und den mittleren `bhd` hinzu pro Gebiet.

**9.5 'long' and 'wide' Datenformate**

Wickham (2014) propagiert das Prinzip von *tidy* Data. Nach diesem Prinzip sollten Daten wie folgt organisiert sein:

- Jede Zeile ist ein Merkmalsträger/Subjekt/Objekt (z.B. eine Person, ein Baum).
- Jede Spalte ist eine Variable (=Merkmal) die den Merkmalsträger beschreibt.
- Jede Zelle ist genau ein Wert (=Merkmalausprägung), nämlich der Wert, der Variable für den Merkmalsträger.

Zum Beispiel enthalten Spaltennamen oft Informationen, die eigentlich in einer Variable gespeichert werden sollten. Folgendes Beispiel gibt die BHD Messung von 3 Bäumen in 3 Jahren wieder.

```
dat <- tibble(
  id = 1:3,
  bhd2015 = c(30, 31, 32),
  bhd2026 = c(31, 31, 33),
  bhd2017 = c(34, 32, 33)
)
```

Diese Daten sind jetzt im **wide**-Format gespeichert und nicht optimal, weil Information über die Daten (nämlich das Jahr der Aufnahme in den Spaltennamen gespeichert sind). Besser wäre eine Struktur mit nur drei Spalten: `id`, `jahr` und `bhd`. Um die Daten in so eine Struktur zu bringen, gibt es die Funktion `pivot_longer()` aus dem Paket `tidyr`.

```
library(tidyr)
dat1 <- pivot_longer(dat, cols = bhd2015:bhd2017)
dat1
```

```
## # A tibble: 9 x 3
##       id name    value
##   <int> <chr>   <dbl>
## 1     1  1 bhd2015    30
## 2     1  1 bhd2026    31
```

```

1275 ## 3      1 bhd2017    34
1276 ## 4      2 bhd2015    31
1277 ## 5      2 bhd2026    31
1278 ## 6      2 bhd2017    32
1279 ## 7      3 bhd2015    32
1280 ## 8      3 bhd2026    33
1281 ## 9      3 bhd2017    33

```

1282 Wenn wir die Spalten für die Variable und den Wert sinnvoll benennen möchten, können wir das über die  
 1283 Argumente `names_to` und `value_to` machen.

```

dat1 <- pivot_longer(dat, cols = bhd2015:bhd2017, names_to = "jahr", values_to = "bhd")
dat1

```

```

1284 ## # A tibble: 9 x 3
1285 ##       id jahr      bhd
1286 ##   <int> <chr>   <dbl>
1287 ## 1     1 bhd2015    30
1288 ## 2     1 bhd2026    31
1289 ## 3     1 bhd2017    34
1290 ## 4     2 bhd2015    31
1291 ## 5     2 bhd2026    31
1292 ## 6     2 bhd2017    32
1293 ## 7     3 bhd2015    32
1294 ## 8     3 bhd2026    33
1295 ## 9     3 bhd2017    33

```

1296 Analog zu der Funktion `pivot_longer()` gibt es auch die Funktion `pivot_wider()`, um vom Daten vom  
 1297 long-Format ins wide-Format zu transformieren.

```

pivot_wider(dat1, names_from = jahr, values_from = bhd)

```

```

1298 ## # A tibble: 3 x 4
1299 ##       id bhd2015 bhd2026 bhd2017
1300 ##   <int>   <dbl>   <dbl>   <dbl>
1301 ## 1     1     30     31     34
1302 ## 2     2     31     31     32
1303 ## 3     3     32     33     33

```

1304

### 1305 *Aufgabe 28: Zeitliche Verlauf von BHDs*

---

1307 In der Datei `bhd_3.csv` befinden sich gemessene BHDs (in cm) von unterschiedlichen Bäumen zu unter-  
 1308 schiedlichen Zeitpunkten. Erstellen Sie ein Liniendiagramm, das den zeitlichen (x-Achse) Verlauf der BHDs

(y-Achse) für die unterschiedlichen Bäume darstellt.

## 9.6 Auswählen von Variablen

Sobald die Datensätze etwas umfangreicher werden (d.h. es gibt mehrere Spalten in einem `data.frame`), können innerhalb vieler `dplyr`-Funktionen spezielle Funktionen verwendet werden, um Variablen auszuwählen.

Wenn die genaue Position der Spalten bekannt ist, kann man mit dem `:`-Operator und der Position Spalten auswählen:

```
iris %>% select(1:3) %>% head(3)
```

```
##   Sepal.Length Sepal.Width Petal.Length
## 1           5.1           3.5           1.4
## 2           4.9           3.0           1.4
## 3           4.7           3.2           1.3
```

Diese Vorgehensweise kann gefährlich sein, da sich manchmal Spalten verschieben und sich somit die Positionen ändern. Besser Spalten immer explizit anzusprechen.

```
iris %>% select(Sepal.Length, Sepal.Width, Petal.Length) %>% head(3)
```

```
##   Sepal.Length Sepal.Width Petal.Length
## 1           5.1           3.5           1.4
## 2           4.9           3.0           1.4
## 3           4.7           3.2           1.3
```

`select()` erlaubt es, auch hier den `:`-Operator zu verwenden:

```
iris %>% select(Sepal.Length:Petal.Length) %>% head(3)
```

```
##   Sepal.Length Sepal.Width Petal.Length
## 1           5.1           3.5           1.4
## 2           4.9           3.0           1.4
## 3           4.7           3.2           1.3
```

Es gibt auch einige spezielle Funktionen, um Spalten innerhalb eines `select()`-Aufrufs auszuführen:

- `starts_with()`: Hier kann man ein Muster angeben, mit dem ein Text anfangen muss.
- `ends_with()`: Diese Funktion ist analog zu `starts_with()`, jetzt wird aber am Ende des Spaltennamens nach dem Muster gesucht.
- `contains()`: Hier kann ein Muster übergeben werden, das irgendwo im Spaltennamen sein muss.

- `everything()`: Mit dieser Funktion werden alle Spalten ausgewählt.
- `last_col()`: Mit dieser Funktion wird nur die letzte Spalte ausgewählt (dass ist die Spalte, die ganz rechts ist).

Sämtliche Auswahlen können mit `-` umgekehrt werden.

```
iris %>% select(starts_with("Sepal")) %>% head(3)
```

```
##      Sepal.Length Sepal.Width
## 1           5.1           3.5
## 2           4.9           3.0
## 3           4.7           3.2
```

```
iris %>% select(-starts_with("Sepal")) %>% head(3)
```

```
##      Petal.Length Petal.Width Species
## 1           1.4           0.2  setosa
## 2           1.4           0.2  setosa
## 3           1.3           0.2  setosa
```

`select()` bietet auch noch die Möglichkeit, Spalten namen zu ändern.

```
iris %>% select(sep_width = Sepal.Width) %>% head(3)
```

```
##      sep_width
## 1           3.5
## 2           3.0
## 3           3.2
```

### Aufgabe 29: Auswählen von Spalten

In der Datei `messungen_1.csv` sind Messungen von zwei Sensoren enthalten für die ersten vier Monate eines Jahres. Führen Sie folgende Abfragen durch:

1. Wählen Sie alle Messungen für Januar aus.
2. Wählen Sie alle Messungen für Januar und März aus.

## 9.7 Einzelne Beobachtungen abfragen (`slice()`)

Mit dem Befehl `slice()` kann man einzelne Beobachtungen (= Zeilen) aus einem `data.frame` abfragen.

```
slice(iris, c(1, 9, 18))
```

```
1362 ##      Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1363 ## 1          5.1          3.5          1.4          0.2  setosa
1364 ## 2          4.4          2.9          1.4          0.2  setosa
1365 ## 3          5.1          3.5          1.4          0.3  setosa
```

1366 Davon gibt es drei nützliche Varianten: 1) `slice_head()` und `slice_tail()`; 2) `slice_max()` und  
1367 `slice_min()`; 3) `slice_random()`.

1368 `slice_head()` und `slice_tail()` sind analog zu `head()` und `tail()`, aber mit dem entscheidenden Unter-  
1369 schied, dass Gruppierungen berücksichtigt werden. Wenn keine Gruppierung in den Daten vorhanden ist,  
1370 gibt es keinen Unterschied.

```
iris %>% head(n = 2)
```

```
1371 ##      Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1372 ## 1          5.1          3.5          1.4          0.2  setosa
1373 ## 2          4.9          3.0          1.4          0.2  setosa
```

```
iris %>% slice_head(n = 2)
```

```
1374 ##      Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1375 ## 1          5.1          3.5          1.4          0.2  setosa
1376 ## 2          4.9          3.0          1.4          0.2  setosa
```

1377 Sobald jedoch eine gruppierende Variable eingeführt wird, gibt `slice_head()` die ersten `n` Beobachtungen  
1378 für jede Gruppe zurück und `head()` für den gesamten Datensatz.

```
# base head
iris %>% group_by(Species) %>%
  head(n = 2)
```

```
1379 ## # A tibble: 2 x 5
1380 ## # Groups:   Species [1]
1381 ##      Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1382 ##          <dbl>         <dbl>         <dbl>         <dbl> <fct>
1383 ## 1          5.1          3.5          1.4          0.2  setosa
1384 ## 2          4.9          3          1.4          0.2  setosa
```

```
# dplyr slice_head
iris %>% group_by(Species) %>%
  slice_head(n = 2)
```



```

1385 ## # A tibble: 6 x 5
1386 ## # Groups:   Species [3]
1387 ##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1388 ##         <dbl>         <dbl>         <dbl>         <dbl> <fct>
1389 ## 1         5.1         3.5         1.4         0.2 setosa
1390 ## 2         4.9         3         1.4         0.2 setosa
1391 ## 3         7         3.2         4.7         1.4 versicolor
1392 ## 4         6.4         3.2         4.5         1.5 versicolor
1393 ## 5         6.3         3.3         6         2.5 virginica
1394 ## 6         5.8         2.7         5.1         1.9 virginica

```

1395 `slice_tail()` funktioniert analog zu `slice_head()` mit dem einzigen Unterschied, dass nicht die ersten `n`  
 1396 Zeilen zurück gegeben werden sondern die letzten `n` Zeilen.

1397 `slice_max()` und `slice_min()` geben die Beobachtung mit dem maximalen bzw. minimalen Wert einer  
 1398 Variable zurück. Auch hier werden Gruppen berücksichtigt.

```
iris %>% slice_max(Sepal.Length)
```

```

1399 ##   Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
1400 ## 1         7.9         3.8         6.4         2 virginica

```

1401 Und mit Gruppen:

```
iris %>% group_by(Species) %>%
  slice_max(Sepal.Length)
```

```

1402 ## # A tibble: 3 x 5
1403 ## # Groups:   Species [3]
1404 ##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1405 ##         <dbl>         <dbl>         <dbl>         <dbl> <fct>
1406 ## 1         5.8         4         1.2         0.2 setosa
1407 ## 2         7         3.2         4.7         1.4 versicolor
1408 ## 3         7.9         3.8         6.4         2   virginica

```

1409 `slice_min()` funktioniert genau gleich, nur dass die Beobachtung (=Zeile) mit dem kleinsten Wert einer  
 1410 Variable zurück gegeben wird.

1411 Die Funktion `slice_sample()` erlaubt es zufällige Beobachtungen zu ziehen. Dabei kann über das Argument  
 1412 `n` die Anzahl an Beobachtungen angegeben werden oder über das Argument `prop` der Anteil an Beobach-  
 1413 tungen.

```
slice_sample(iris, n = 5)
```

```

1414 ## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1415 ## 1          6.5          2.8          4.6          1.5 versicolor
1416 ## 2          6.3          3.3          4.7          1.6 versicolor
1417 ## 3          7.2          3.2          6.0          1.8 virginica
1418 ## 4          4.9          3.6          1.4          0.1 setosa
1419 ## 5          6.0          2.7          5.1          1.6 versicolor

```

Das Ergebnis ist bei jedem von Ihnen anders, da es sich um eine zufällige Ziehung handelt. Wenn Sie diese Ergebnisse wiederholen möchte, können Sie über `set.seed()` die zufällige Ziehung reproduzierbar machen.

```

set.seed(123)
slice_sample(iris, n = 5)

```

```

1422 ## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1423 ## 1          4.3          3.0          1.1          0.1 setosa
1424 ## 2          5.0          3.3          1.4          0.2 setosa
1425 ## 3          7.7          3.8          6.7          2.2 virginica
1426 ## 4          4.4          3.2          1.3          0.2 setosa
1427 ## 5          5.9          3.0          5.1          1.8 virginica

```

Wenn beispielsweise 5% der Beobachtungen gezogen werden sollen, kann dies so gemacht werden:

```

slice_sample(iris, prop = 0.05)

```

```

1429 ## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1430 ## 1          7.7          3.8          6.7          2.2 virginica
1431 ## 2          5.5          2.5          4.0          1.3 versicolor
1432 ## 3          5.5          2.6          4.4          1.2 versicolor
1433 ## 4          6.5          3.0          5.2          2.0 virginica
1434 ## 5          6.1          3.0          4.6          1.4 versicolor
1435 ## 6          6.3          3.4          5.6          2.4 virginica
1436 ## 7          5.1          2.5          3.0          1.1 versicolor

```

`slice_sample()` berücksichtigt ebenfalls Gruppen. Mit den Argumenten `replace` und `weight_by` dann die Zufallsziehung genauer spezifiziert werden. `replace` sagt, ob eine gezogene Beobachtung wieder zurück gelegt wird oder nicht. Mit dem Argument `weight_by` können optional gewichte für jede Beobachtung vergeben werden.

1441

### 1442 *Aufgabe 30: Daten beschreiben*

1443

Verwenden Sie den Datensatz `bhd_1.txt` und finden Sie für jedes Gebiet und Art die Beobachtung mit kleinsten BHD.

1445

## 9.8 Spalten trennen

Ein gut geplanter Datensatz besteht aus Beobachtungen (Zeilen), Variablen (Spalten) und in jeder Zelle ist immer ein *genau* ein Wert gespeichert. Leider gibt es oft Datensätze, bei denen mehr als ein Wert pro Zelle gespeichert wurde. Die Funktion `seperate()` kann helfen solche Daten zu trennen.

Wir verwenden einen erfunden Datensatz zu Beobachtungen von Tieren und einer geschätzten Distanz zu diesen Tieren.

```
dat <- tibble(
  id = 1:4,
  beobachtung = c("10m, Reh", "100m, Reh", "20m, Fuchs", "40,Reh"),
)
```

In der Spalte `beobachtung` sind zwei Informationen gespeichert: Die Distanz zur Beobachtung und die Art. Das ist ungünstig, weil wir so weder nach Tierart noch nach `distanz` filtern können. Mit der Funktion `seperate()`, können wir Beobachtungen einer Spalte in mehrere Spalten trennen. Dafür muss der Spaltennamen (Argument `col`), die neuen Spaltennamen (Argument `into`) und das Trennzeichen (Argument `sep`) angegeben werden.

```
separate(dat, col = beobachtung, into = c("Distanz", "Art"), sep = ",")
```

```
## # A tibble: 4 x 3
##       id Distanz Art
##   <int> <chr>   <chr>
## 1     1  10m    " Reh"
## 2     2 100m    " Reh"
## 3     3  20m    " Fuchs"
## 4     4   40    "Reh"
```

Nach dem Aufruf von `seperate()` gibt es zwei neue Spalten (`Distanz` und `Art`), die die alte Spalte `beobachtung` ersetzen.

### Aufgabe 31: Aufräumen

Verwenden Sie den folgenden Datensatz und bringen Sie ihn in eine Form, die sicherstellt dass

- jede Zelle genau einen Wert enthält.
- jede Zeile eine Beobachtung ist.
- die Spaltennamen aus einem ausschlagkräftigen Wort bestehen.

```
dat <- data.frame(  
  standort = c("a1", "a2", "b1", "b2"),  
  j2019 = c("3 x Fuchs", "4 x Reh", "1 x Fuchs", "2 x Reh"),  
  j2020 = c("2 x Fuchs", "1 x Reh", "", "2 x Fuchs")  
)
```

## 10 Arbeiten mit Text

Bis jetzt haben wir fast ausschließlich mit Zahlen oder Abbildungen gearbeitet. R bietet aber auch viele Werkzeuge, um mit Text zu arbeiten. Wir wollen hier ein paar Funktionen dafür vorstellen. Als erstes sollte nochmals klargestellt werden, was eigentlich ein Text ist. In R ist alles, das innerhalb von doppelten (") oder einfachen (') Anführungszeichen geschrieben ist, Text.

Anbei einige Beispiele:

```
a <- "Das ist ein kurzer Satz."
b <- "Auch das ist 'moeglich'."
z <- "30"
```

Wichtig ist hier zu sehen, dass `z` nicht als Zahl sondern, als Text interpretiert wird.

```
z + 1
```

```
## Error in z + 1: nicht-numerisches Argument für binären Operator
```

Wenn man sicher ist, dass es sich bei einem Textobjekt um eine Zahl handelt, kann man dies mit der Funktion `as.numeric()` in eine Zahl umwandeln.

```
as.numeric(z) + 1
```

```
## [1] 31
```

Aber mit `a` führt dies wieder zu einem NA-Wert, da `a` nicht in eine Zahl umgewandelt werden kann.

```
as.numeric(a) + 1
```

```
## Warning: NAs durch Umwandlung erzeugt
```

```
## [1] NA
```

### 10.1 Arbeiten mit Text

Wir wollen erst einmal drei Funktionen besprechen, die es erlauben mit Text zu arbeiten. Die Funktion `nchar()`<sup>11</sup> gibt an wie viele Zeichen ein Text hat. Also z.B.

```
nchar("Hallo")
```

```
## [1] 5
```

---

<sup>11</sup>`char` ist kurz für *character*.

```
nchar("30")
```

```
1491 ## [1] 2
```

```
nchar("Hallo und Guten Tag!")
```

```
1492 ## [1] 20
```

1493 Die Funktion `paste()` erlaubt es verschiedene Variablen mit Text zu verbinden. Wenn wir z. B. die Variablen `vorname <- "Eva"` und `name <- "Meier"` haben und wir wollen eine neue Variable `full_name <- "Eva Meier"` erzeugen, dann kann das mit der Funktion `paste()` gemacht werden.

```
vorname <- "Eva"
name <- "Meier"
full_name <- paste(vorname, name)
full_name
```

```
1496 ## [1] "Eva Meier"
```

1497 Die Funktion `paste()` hat das Argument `sep`, das auf ein Leerzeichen ( ) gesetzt ist, aber auch anders sein kann und das Trennzeichen definiert.

```
full_name <- paste(vorname, name, sep = ", ")
full_name
```

```
1499 ## [1] "Eva, Meier"
```

1500 Die Funktion `substr()` erlaubt es am Anfang oder Ende eines Wortes etwas abzuschneiden. Dabei muss immer die Anfangs- (`start`) und Endposition (`stop`) angegeben werden.

```
substr("Hallo", start = 1, stop = 3)
```

```
1502 ## [1] "Hal"
```

```
substr("Hallo", start = 2, stop = 5)
```

```
1503 ## [1] "allo"
```

```
1504
```

### 1505 *Aufgabe 32: Arbeiten mit Text 1*

---

1507 Verwenden Sie den folgenden Vektor:

```
txt <- c("Versicherung", "Vogel", "Station", "Gutschein", "Statistik", "Stift",
        "Methoden", "Fluss", "Rudel", "Baum", "Haus", "Wahrscheinlich", "Foto",
        "Seife", "Garten", "Auto", "Handy", "Teller", "Kalender")
```

1. Aus wie vielen Buchstaben besteht jedes Wort?
2. Finden Sie das längste Wort.
3. Wie viel Prozent der Wörter fangen mit einem S an?
4. Fügen Sie jedem Wort seine Position im Vektor hinzu. Beispielsweise soll aus `Vogel` "2. Vogel" werden usw.

## 10.2 Finden von Textmustern

Mit der Funktion `grep()` können Muster in einem Text gefunden werden. Wenn wir beispielsweise folgenden Vektor mit Textelementen haben.

```
txt <- c("Buesgenweg", "Friedlaender Weg", "Berliner Strasse")
```

Und wir wollen alle Straßennamen die ein `weg` haben abfragen, dann können wir folgenden Befehl ausführen:

```
grep("Weg", txt)
```

```
## [1] 2
```

Im zweiten Element von `txt` kommen die Zeichen `Weg` vor. Beachte, in der Standardeinstellung wird zwischen Groß- und Kleinschreibung unterschieden. Dies kann mit dem Argument `ignore.case = TRUE` angepasst werden.

```
grep("Weg", txt, ignore.case = TRUE)
```

```
## [1] 1 2
```

Mit der Funktion `sub` können Zeichen innerhalb einer Zeichenkette ersetzt werden.

So ersetzt der folgende Ausdruck `ae` mit `ä`.

```
sub("ae", "ä", "Friedlaender Weg")
```

```
## [1] "Friedländer Weg"
```

Wenn allerdings das zu ersetzende Zeichen mehr als einmal vorkommt und beide Instanzen ersetzt werden sollen braucht man die Funktion `gsub`.

```
txt <- "Friedlaender Weg und Reinhaeuser Landstrasse sind zwei Strassen in Goettingen."
sub("ae", "ä", txt)
```

```
## [1] "Friedländer Weg und Reinhaeuser Landstrasse sind zwei Strassen in Goettingen."
```

Mit `sub()` wird nur das erste `ae` ersetzt, während `gsub()` *alle* `ae` mit einem `ä` ersetzt.

```
gsub("ae", "ä", txt)
```

```
## [1] "Friedländer Weg und Reinhäuser Landstrasse sind zwei Strassen in Goettingen."
```

Oft ist der genaue Ausdruck den man finden möchte jedoch Variable. Beispielsweise möchte man alle Wörter mit einem Umlaut oder Zahlen finden möchte, kann man das oft abkürzen. Dafür gibt es reguläre Ausdrücke. Wir werden hier nur ein paar beispielhafte Anwendungen besprechen.

Sowohl in den Funktionen `grep()` als auch `(g)sub()` kann mit anstatt dem Muster (immer das erste Argument) aus ein regulärer Ausdruck angegeben werden. Mit `[1-9]` sind alle Zahlen von 1 bis 9 gemeint.

Das Ziel ist es jetzt alle Straßen zu finden, die auch einen Straßennummer haben:

```
txt <- c("Büsgenweg 1", "Berliner Strasse", "Kurze Strasse 13")
```

```
grep("[0-9]", txt)
```

```
## [1] 1 3
```

Damit lässt sich auch das Problem mit groß- und kleingeschriebenen Wörtern lösen.

```
txt <- c("Buesgenweg", "Friedlaender Weg", "Berliner Strasse")
grep("[wW]eg", txt)
```

```
## [1] 1 2
```

1539

### 1540 *Aufgabe 33: Arbeiten mit Text 2*

1541

1542 Verwenden Sie den folgenden Vektor:

```
txt <- c("Versicherung", "Methoden", "Fluss", "Rudel",
        "Baum", "Haus", "Foto", "Auffahrt", "Auto", "Handy", "Teller",
        "Kalender", "Aufbau")
```



- 1543 1. In wie vielen Wörtern kommt der Doppellaut **au** vor?
- 1544 2. Ersetzen Sie in allen Wörtern alle **au** mit **\_ \_**.

```
grep("au", txt)
```

```
1545 ## [1] 5 6 13
```

```
gsub("au", "_ _", txt)
```

```
1546 ## [1] "Versicherung" "Methoden" "Fluss" "Rudel" "B_ _m"
1547 ## [6] "H_ _s" "Foto" "Auffahrt" "Auto" "Handy"
1548 ## [11] "Teller" "Kalender" "Aufb_ _"
```

## 11 Arbeiten mit Zeit

Für den Computer bzw. R ist ein Datum erst einmal nichts anderes als ein Text. Für uns ist es sofort klar, dass der "13.2.2021" der 13. Februar 2021 ist, für den Computer nicht. Wir müssen R also irgendwie sagen, dass die 13 der Tag ist, die 2 der Monat und 2021 das Jahr. Dass der Computer die einzelnen Komponenten erkennt, nennt man *parsen*<sup>12</sup>. Das Arbeiten mit Datum und Zeit kann anfangs sehr mühsam sein, aber sobald man einige Grundfertigkeiten erworben hat, kann man viele Aufgaben deutlich schneller und effizienter erledigen. Der erste Schritt ist immer ein Datum zu *parsen*. Wir verwenden dafür Funktionen aus dem Paket `lubridate`. Als erstes müssen wir wieder Paket `lubridate` laden mit:

```
library(lubridate)
```

`lubridate` bietet eine Vielzahl von Funktionen zum *parsen* von Datum und Zeit, die sich aus:

- `y` für Jahr,
- `m` für Monat,
- `d` für Tag,
- `h` für Stunde,
- `m` für Minute und
- `s` für Sekunde

zusammen setzten. Alle Funktionen nehmen als erstes Argument ein Textstring. Wenn wir z.B. den String "2020-01-20" parsen wollen können wir das mit der Funktion `ymd` machen.

```
ymd("2020-01-20")
```

```
## [1] "2020-01-20"
```

Dabei erkennt `lubridate` in der Regel die Trennzeichen:

```
ymd("2020.01.20")
```

```
## [1] "2020-01-20"
```

```
ymd("2020/01/20")
```

```
## [1] "2020-01-20"
```

```
ymd("2020 01 20")
```

```
## [1] "2020-01-20"
```

<sup>12</sup>to *parse* heißt zergliedern bzw. grammatikalisch bestimmen.

1571 Wenn die die Anordnung der einzelnen Komponenten anders ist, gibt es einfach eine andere Funktion.

```
dmy("20.1.2020")
```

1572 ## [1] "2020-01-20"

1573 Jetzt stellt sich die Frage, was der Vorteil ist, wenn R ein Datum parst.

```
d <- dmy("20.1.2020")
```

1574 Wir können jetzt mit `d` arbeiten und einzelne Komponenten extrahieren.

```
day(d)
```

1575 ## [1] 20

```
month(d)
```

1576 ## [1] 1

```
year(d)
```

1577 ## [1] 2020

1578 Oder auch Zeiteinheiten hinzufügen oder abziehen.

```
d + days(10)
```

1579 ## [1] "2020-01-30"

```
d - years(20)
```

1580 ## [1] "2000-01-20"

```
d + hours(25)
```

1581 ## [1] "2020-01-21 01:00:00 UTC"

1582

### 1583 *Aufgabe 34: Arbeiten mit Datum und Zeit*

---

1584

- 1585 • Parsen Sie folgende Zeitangaben 23.1.2020, 13.2.1992 20:55:23, Mar/3/97 und 10.7.2020 19:15  
1586 und speichern Sie diese in einen Vektor `d`.
- 1587 • Extrahieren Sie nun aus jedem Element aus `d` das Jahr und die Stunde.
- 1588 • Fügen zu jedem Element in `d` 10 Tage hinzu.

## 11.1 Arbeiten mit Zeitintervallen

Mit zwei Zeitpunkten lassen sich Zeitintervalle (**Periods**) erstellen, dafür können wir die Funktion `interval()` aus dem Paket `lubridate` verwenden<sup>13</sup>.

```
anfang <- ymd("2020-03-18")
ende <- anfang + years(1)

int <- interval(anfang, ende)
```

Wir können jetzt mit `int` arbeiten und beispielsweise das Intervall verschieben,

```
int_shift(int, years(3))
```

```
## [1] 2023-03-18 UTC--2024-03-18 UTC
```

die Länge des Intervalls berechnen

```
int_length(int) # in Sekunden
```

```
## [1] 31536000
```

oder testen ob ein Datum innerhalb des Intervalls liegt.

```
ymd("2020-07-1") %within% int
```

```
## [1] TRUE
```

```
ymd("2021-07-1") %within% int
```

```
## [1] FALSE
```

`%within%` funktioniert genauso mit Vektoren oder mit mehreren Intervallen. Wir könnten also zwei Intervalle definieren (z.B. Ostern und Pfingsten).

```
ostern <- ymd("2021-04-02") %--% ymd("2021-04-05")
pfingsten <- ymd("2021-05-22") %--% ymd("2021-05-24")
```

Und Überprüfen welche Termine in eines der zwei Intervalle fallen.

<sup>13</sup>Alternativ zur Funktion `interval()` kann auch der `%--%`-Operator verwendet werden. Man könnte `int` auch so erstellen `int <- anfang %--% ende`.

```
termine <- ymd("2021-03-29") + weeks(0:10)
```

```
# Ostern
```

```
termine %within% ostern
```

```
## [1] FALSE TRUE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
```

```
# Pfingsten
```

```
termine %within% pfingsten
```

```
## [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE TRUE FALSE FALSE
```

## 11.2 Formatieren von Zeit

Für die Ausgabe in Berichten oder Grafiken soll das Datum oft in einer speziellen Form dargestellt werden.

Die Funktion `format()` bietet Möglichkeiten ein Datumsobjekt zurück in Text umzuwandeln.

Ein Beispiel wäre `ymd("2021-2-10")` als 10.2.21 auszugeben.

```
d <- ymd("2021-2-21")
```

```
format(d, "%d.%m.%y")
```

```
## [1] "21.02.21"
```

Dabei handelt sich bei `%d.%m.%y` um Abkürzungen für die unterschiedlichen Komponenten eines Datumobjekts. Siehe dazu die Hilfeseite von `strptime` (`help(strptime)`).

1611

### Aufgabe 35: Arbeiten mit Intervallen

Wie viele Einträge aus dem Vektor `v1` befinden sich in einem Intervall, das zwischen dem 1.3.2021 und dem 5.3.2021 definiert ist.

```
v1 <- c(
  "2021-03-05", "2021-03-03", "2021-03-09", "2021-03-09", "2021-03-09",
  "2021-03-03", "2021-03-08", "2021-03-10", "2021-03-07", "2021-03-10"
)
```

## 12 Aufgaben Wiederholen (for-Schleifen)

Um einfache Programme zu schreiben, müssen Sie den Ablauf der Programmcodes kontrollieren können. Kontrollieren bedeutet in diesem Zusammenhang, dass Codeabschnitte nur unter definierten Bedingungen ablaufen. Sie programmieren also zwei Sachen. 1) den Code selbst und 2) die Bedingungen die erfüllt sein müssen, damit der Code ausgeführt wird. Diese Kontrollbedingungen ermöglichen es Ihnen generisch zu programmieren. Sie schreiben Ihren Code also nicht speziell maßgeschneidert für ein Problem, sondern so generell, dass er für mehrere Auswertungen funktioniert. Um dies zu gewährleisten müssen Sie bestimmte Situationen vorhersehen und abfangen. Hierbei helfen Ihnen Kontrollstrukturen (**Control Flow**). Grundsätzlich gibt es **Control Flow** Funktionen zur Wiederholung von Codeblöcken (Schleifen) und logische Bedingungen (bedingte Anweisung).

### 12.1 Schleifen

Bis jetzt wurden alle Skripte einfach der Reihe nach abgearbeitet und zwischendurch bestimmte Programmteile, je nach Situation, selbstständig ausgeführt oder übersprungen. Mit einer Schleife kann man erreichen, dass eine Gruppe von Befehlen (der sog. Schleifenrumpf) mehrfach abgearbeitet wird, zum Beispiel wenn bestimmte Auswertungsschritte auf mehrere Datensätze oder Variablen angewendet oder Funktionen mit unterschiedlichen Parametern oder Startwerten aufgerufen werden sollen. Weitere Anwendungsmöglichkeiten sind iterative Algorithmen, in denen die Eingabewerte des aktuellen Iterationsschrittes von einem vorherigen abhängig sind. Besonders in Simulationen kommen Schleifen häufig zum Einsatz, da große Anzahlen von Wiederholungen benötigt werden.

Man unterscheidet zwischen zwei Arten von Schleifen: Bei den **for()**-Schleifen steht die Anzahl der Wiederholungen schon beim Eintritt in die Schleife fest, während die **while()**-Schleifen so lange ausgeführt werden, bis eine Bedingung nicht mehr wahr ist. Mit der Funktion **break** wird eine Schleife abgebrochen und die Programmausführung wird nach der Schleife fortgesetzt.

Die wesentlichen Befehle sind

- **for (i in X) {Code}**

Wiederhole den Code im “Schleifenrumpf” für jedes Element aus **X**.

- **while(Bedingung) {Code}**

Wiederhole den Code im “Schleifenrumpf” so lange die logische Bedingung erfüllt ist.

- **break()**

Brich die Schleife ab.

### 12.1.1 Wiederholen von Befehlen mit `for()`.

Steht vor Beginn der Schleife fest wie viele Schleifendurchgänge benötigt werden, wenn zum Beispiel in einer Simulationen 99 Realisierungen erzeugt oder alle Elemente eines Vektors verarbeitet werden sollen, verwendet man eine `for`-Schleife. Die allgemeine Form der `for`-Schleife ist:

```
X <- c(1 : 3) # Einträge die im Schleifenrumpf abgearbeitet werden.
for(i in X){
  # Schleifenrumpf
  print(i)
}
```

```
## [1] 1
## [1] 2
## [1] 3
```

Das `i` steht in diesem Beispiel für die Schleifen-Variable. Sie muss nicht `i` heißen, sondern kann jeden zulässigen Namen annehmen. Das `X` steht für einen existierenden Vektor oder eine existierende Liste bzw. einen Ausdruck, der ein solches Objekt liefert (der Objektname ist ebenfalls frei wählbar). `for` und `in` sind Schlüsselworte, sie müssen, ebenso wie die runden Klammern, vorhanden sein.

Im ersten Durchgang erhält die Schleifen-Variable `i` den ersten Wert von `X` und der Schleifenrumpf wird mit diesem Wert ausgeführt. Die Variable `i` nimmt nacheinander so lange die Werte von `X` an, bis ihr alle Elemente zugewiesen wurden.

Das folgende Beispiel wird zwar besser durch die entsprechende Vektoroperation gelöst, zeigt aber sehr deutlich die Arbeitsweise der `for`-Schleife.

```
zahlen <- c(2, 3, 5)

for(element in zahlen){
  print(element^2)
}
```

```
## [1] 4
## [1] 9
## [1] 25
```

### Aufgabe 36: Schleifen 1

Verwenden Sie den Vektor `k <- c(1, 3, 9, 12, 15)` und schreiben Sie folgende `for`-Schleifen:

1. Eine Schleife, die jedes Element aus `k` ausgibt.

2. Eine Schleife, die zu jedem Element aus `k` 10 addiert und den neuen Wert ausgibt.
3. Eine Schleife wie in 2), aber der neue Wert ( $k + 10$ ) soll jetzt nicht mehr ausgegeben werden, sondern in `k10` gespeichert werden. Stellen Sie sicher, dass `k10` wieder von der Länge 5 ist.

Die Funktion `for()` ermöglicht es, einen Befehl beliebig oft zu wiederholen. Z.B. der folgende Ausdruck zieht 10-Mal eine Stichprobe der Größe 1 aus dem Vektor `v`. Beachten Sie, dass die Schleifen-Variable `i` selbst gar nicht im Schleifenrumpf vorkommt. Das Ziel dieser Schleife ist nicht die Elemente des Vektors abzuarbeiten, sondern einfach nur den Ausdruck im Schleifenrumpf 10-Mal zu wiederholen.

```
v <- c(1, 4, 2, 3)
for (i in c(1 : 10)) {
  print(sample(v, 1))
}
```

```
## [1] 3
## [1] 4
## [1] 2
## [1] 4
## [1] 1
## [1] 4
## [1] 2
## [1] 3
## [1] 4
## [1] 1
```

Auf gleiche Weise kann man auch über die Variablen eines Dataframes iterieren<sup>14</sup>. Das folgende Beispiel hat zum Ziel die Funktionsweise von Schleifen zu verdeutlichen. Schleifen haben in R jedoch den Nachteil, dass sie sehr langsam operieren. Wenn es geht, sollte man Alternativen verwenden. Die Funktionsweise wiederholender Auswertungen wird jedoch mit `for`-Schleifen deutlicher. Aus diesem Grunde werden wir uns in diesem Kurs auf Schleifen beschränken.

```
myLoopDf <- data.frame(a = c(2, 4, 7, 5),
                      b = c("Buche", "Eiche", "Eiche", "Buche"),
                      d = c(50, 60, 55, 80))

for (i in c(1 : 4)) {
  summeAd <- myLoopDf[i, "a"] + myLoopDf[i, "d"]
  print(myLoopDf$b[i])
  print(summeAd)
}
```

<sup>14</sup>Zur Info: Dieses Beispiel lässt sich schneller mittels der vektorwertigen Operation `apply()` lösen.



```
1693 ## [1] "Buche"
1694 ## [1] 52
1695 ## [1] "Eiche"
1696 ## [1] 64
1697 ## [1] "Eiche"
1698 ## [1] 62
1699 ## [1] "Buche"
1700 ## [1] 85
```

1701

### 1702 Aufgabe 37: for-Schleife

---

1703

1704 Lesen Sie den Datensatz `bhd_1.txt` ein und verwenden Sie eine `for`-Schleife.

- 1705 • Ziehen Sie 500-Mal je 35 Beobachtungen für den BHD.
- 1706 • Berechnen Sie jeweils den Mittelwert aus den 35 Werten.
- 1707 • Speichern Sie die 500 Mittelwerte in einem neuen Vektor `mittel`.
- 1708 • Wie ist die Verteilung dieser 500 Mittelwerte zu interpretieren?

#### 1709 12.1.2 Wiederholen von Befehlen mit `while()`

1710 Die `while`-Schleifen finden Anwendung, wenn die Anzahl der zu durchlaufenden Wiederholungen vorher  
1711 nicht bekannt ist, wie zum Beispiel bei Iterationsverfahren, die bis zu einer gewissen Genauigkeit durchlaufen  
1712 werden sollen. Die `while`-Schleife besteht in R aus dem Schlüsselwort `while()` und einer Bedingung in runden  
1713 Klammern.

```
while (Bedingung) {  
  # Schleifenrumpf  
}
```

1714 Sie ist in der praktischen Programmierung nicht so relevant wie die `for`-Schleife. Sie sei deshalb hier nur  
1715 kurz erwähnt. Die Abbruchbedingung wird jedes Mal geprüft bevor der Schleifenrumpf durchlaufen wird.  
1716 Die Bedingung wird ausgewertet und wenn diese `TRUE` ist, wird der Schleifenrumpf ausgeführt und danach  
1717 erneut die Bedingung überprüft. Ist die Bedingung nicht erfüllt, wird der Schleifenrumpf nicht durchgeführt  
1718 und die Schleife beendet. Ist die Bedingung bereits vor Eintritt in die Schleife nicht erfüllt, wird die Schleife  
1719 gar nicht erst durchlaufen.

1720 Da `while`-Schleifen also so lange ausgeführt werden, bis die Bedingung nicht mehr erfüllt ist, kann eine  
1721 Endlosschleife entstehen. Dies kann passieren, wenn man nicht sauber programmiert hat. Wenn innerhalb  
1722 der Schleife nicht dafür gesorgt wird, dass die Bedingung irgendwann nicht mehr erfüllt wird, so läuft die  
1723 Schleife immer weiter. Steckt R in einer Schleife fest und reagiert nicht mehr, kann der Befehl unter Linux  
1724 mit `[Strg]+[C]` und unter Windows mit `[Esc]` abgebrochen werden. Alternativ können Sie auf das rote STOP  
1725 Symbol über der Konsole klicken.

## 12.2 Bedingte Ausführung von Codeblöcken

Innerhalb eines Skripts ist es mitunter notwendig je nach aktueller Situation unterschiedlich fortzufahren. Die Situation wird mit einem logischen Ausdruck, einer sogenannten Bedingung, geprüft. Je nachdem, ob die Bedingung wahr (`TRUE`) oder falsch (`FALSE`) ist, werden unterschiedliche Programmteile ausgeführt, der jeweils andere Teil bleibt unberücksichtigt. Danach wird in jedem Fall die Programmausführung, mit den auf die bedingte Anweisungen folgenden Anweisung, fortgesetzt. In R kann dies mit dem `if-else`-Konstrukt realisiert werden, welches aus den Schlüsselwörtern `if()` und `else` sowie der in runde Klammern gefassten Bedingung besteht.

```
if(Bedingung){  
  # Anweisungen für Bedingung == TRUE  
} else{  
  # Anweisungen für Bedingung == FALSE  
}
```

Im folgenden Beispiel sollen die bisher abstrakt beschriebenen Vorgänge praktische Anwendung finden. In dem Beispiel wird zunächst durch zufälliges Ziehen einer Zahl aus dem Bereich eins bis sechs ein Würfelwurf simuliert. Anschließend wird der Würfelwurf mit einem `if`-Ausdruck kommentiert. Ist die Bedingung, es wurde eine Sechs gewürfelt, erfüllt, wird der Code innerhalb der geschweiften Klammern ausgeführt, ansonsten wird der Klammerinhalt ignoriert.

```
# Würfelwurf simulieren  
x <- sample(1:6, 1)  
# if-Konstrukt zur passgenauen Gratulation  
if (x == 6) {  
  print("Glückwunsch, eine Sechs!")  
}
```

In den meisten Fällen ist es für R irrelevant, ob sich zwischen den verschiedenen Elementen Leerzeichen oder Zeilenumbrüche befinden. Bei dem `else`-Ausdruck dagegen wird ein Fehler erzeugt, wenn vor dem `else` nicht die geschweifte Endklammer der vorausgehenden `if`-Bedingung steht.

```
# Würfelwurf simulieren  
x <- sample(1:6, 1)  
# if-else-Konstrukt: Gratulation oder Ermutigung  
if(x == 6){  
  print("Glückwunsch, eine Sechs!")  
} else{  
  print("Beim nächsten Wurf klappt's bestimmt.")  
}
```

```
## [1] "Beim nächsten Wurf klappt's bestimmt."
```

1743

---

**Aufgabe 38: Bedingte Programmierung**

---

1744  
1745

- 1746 • Wenn keine 6 gewürfelt wurde, lassen Sie zusätzlich ausgeben welche Zahl gewürfelt wurde.
- 1747 • Wiederholen Sie den Würfelwurf 10 Mal.

## 13 (R)markdown

### 13.1 Markdown Grundlagen

Die Idee von Markdown ist, einfach Text strukturieren zu können und das ganze ohne umfangreiche Programme zu erstellen. Im nächsten Abschnitt sehen wir dann, wie man Markdown und R-Code verbinden kann. Hier soll es jedoch erst einmal darum gehen, die einfachsten Bausteine von Markdown vorzustellen.

Am Anfang jedes Dokuments kommt eine Präambel. Diese fängt mit `---` an und hört auch wieder mit `---` auf. Innerhalb der Präambel können dann Metainformationen über das Dokument festgelegt werden, dies beinhaltet im einfachsten Fall: Titel, Autor und Datum. Das würde dann so aussehen:

```
---
title: "Ein Titel"
author: "Der, der es geschrieben hat"
date: "März 2021"
---
```

Danach folgt strukturierter und formatierter Text. Verschiedene Hierarchieebenen von Überschriften können mit der Anzahl an `#` festgelegt werden. So ist eine Überschrift erster Ordnung `# Kapitel` eine Überschrift zweiter Ordnung `## Unterkapitel` usw.

Listen können erstellt werden, wenn man am Anfang jeder Zeile ein `-` oder `1.` schreibt.

```
- Erster Eintrag
- Zweiter Eintrag
- Dritter Eintrag
```

wird zu

- Erster Eintrag
- Zweiter Eintrag
- Dritter Eintrag

Eine zentrale Idee von Markdown ist es Text einfach zu formatieren. Werden eine oder mehrere Wörter mit zwei Sternchen (`**`) eingefasst wird dieser Text **fett** dargestellt. Also aus `**wichtig**` wird **wichtig**. Das gleiche funktioniert auch mit *kursiven* Text, jedoch muss man hier noch ein Sternchen verwenden, also aus `*kursiv*` wird *kursiv*. Soll ein text fett und kursiv sein, kann man drei Sternchen verwenden. Aus `***sehr wichtig***` wird dann ***sehr wichtig***.

Weitere Elemente wie Links oder Abbildungen können einfach eingebunden werden. Links werden mit `[Link text](url)` in den Text integriert. Beispielsweise ist eine gute Idee bei [stackoverflow](https://stackoverflow.com) bei Problemen nach einer Lösung zu suchen. Dieser Link wurde mit `[stackoverflow](www.stackoverflow.com)` erstellt.

Für Abbildungen gibt es einen ganz ähnlichen Syntax. Mit `![Das R Logo](abb/r_logo.png)` wird die Abbildung `r_logo.png` eingebunden mit der Beschriftung: "Das R Logo".



Abbildung 9: Das R Logo

### Aufgabe 39: Arbeiten mit markdown

Verwenden Sie das folgende Markdownokument:

```
---
title: "Dokument"
author: "Ihr Name"
date: "März 2021"
---
```

# Einleitung

# Methoden

1. Kopieren Sie die Vorlage in ein Dokument, das `test.md` heißt.
2. Fügen Sie zwei Überschriften zweiter und dritter Ordnung hinzu.
3. Fügen Sie einen *kursiven* Text hinzu.
4. Fügen Sie einen Link zu einer Website hinzu.
5. Kompilieren Sie die Datei, indem Sie in Rstudio auf **Preview** drücken (Abbildung 10).




Abbildung 10: Kompilieren einer md-Datei.

## 13.2 R und Markdown

Markdown macht es bereits einfach Textdokumente und Dokumentationen zu verfassen, aber die wirkliche Stärke liegt in der Möglichkeit R und Markdown zu kombinieren. Man spricht dann von Rmarkdown. Ein weiteres Strukturelement, das wir noch nicht kennen gelernt haben, sind Code-Blöcke.

```
1804 ' ' '
1805 a <- 1:10
1806 a[1]
1807 ' ' '
```

1808 erzeugt

```
1809 a <- 1:10
1810 a[1]
```

1811 Momentan wird noch kein Code ausgeführt, sondern lediglich der Code, als Code dargestellt. Rmarkdown  
 1812 bietet nun die Möglichkeit Code beim *kompilieren*<sup>15</sup> auszuführen. Dafür müssen wir nur einen Code-Block  
 1813 als R-Code-Block kennzeichnen.

```
1814 '{R}'
1815 a <- 1:10
1816 a[1]
1817 ' ' '
```

1818 erzeugt

```
a <- 1:10
a[1]
```

```
1819 ## [1] 1
```

1820 Beachte, die Variable **a** wird beim kompilieren erzeugt und steht dann R zur Verfügung. R-Code-Blöcke  
 1821 werden auch als Code Chunks bezeichnet. Diese Chunks können sehr genau angesprochen und angepasst  
 1822 werden. Einige wichtige Argumente sind:

- 1823 • **echo**: Gibt an, ob der Quelltext angezeigt werden soll oder nicht.
- 1824 • **result**: Gibt an, ob die Ergebnisse gezeigt werden sollen oder nicht.
- 1825 • **eval**: Diese Option gibt an ob der Chunk ausgeführt werden soll oder nicht.

1826

#### 1827 **Aufgabe 40: Arbeiten mit Rmarkdown**

1828

1829 Erstellen Sie eine neue Rmarkdown Datei mit dem Namen **test1.Rmd**. Erstellen Sie zwei Code-Chunks.  
 1830 Der erste soll nicht angezeigt werden und darin werden die Daten geladen (**bhd\_1.txt**). Im zweiten Chunk  
 1831 plotten Sie das Alter der Bäume gegen den BHD. Was passiert mit dem Plot, wenn Sie die Datei kompilieren  
 1832 (drücken Sie dazu auf den **Knit**-Knopf; Abbildung 11).

<sup>15</sup>Unter kompilieren wird hier das Übersetzen eines Markdown Dokuments in ein Ausgabeformat (z.B. pdf oder html) verstanden.



Abbildung 11: Kompilieren einer Rmd-Datei.

## 14 Räumliche Daten in R

### 14.1 Was sind räumliche Daten

Räumliche Daten sind Beobachtungen, wie wir sie schon oft gesehen haben, mit einem räumlichen Bezug. Der Unterschied zu nicht räumlichen Daten liegt darin, dass räumliche Daten eindeutig im *Raum* verortet werden können. Häufig werden sogenannte Geoinformationssysteme (GIS) zum Arbeiten mit räumlichen verwendet. R kann in vielerlei Hinsicht wie ein GIS eingesetzt werden und hier werden einige Grundfunktionalitäten dafür besprochen. Räumliche Daten werden in zwei unterschiedliche Datentypen unterteilt: Vektor- und Rasterdaten. Vektordaten modellieren einzelne Objekte (= *Features*). Rasterdaten modellieren eine Oberfläche.

Vektordaten bestehen aus zwei Komponenten: 1) einer Geometrie, die die Form und Lage der Daten definiert und 2) Attributen, den tatsächlichen Daten. Räumliche Daten werden oft als *Features* bezeichnet. Ein Feature ist die räumliche Einheit einer Beobachtung. Je nach Art der räumlichen Daten können Features entweder Punkte (z.B. ein Baum), Linien (z.B. eine Straße) oder Polygone (z.B. ein See) sein. Auch können mehrere Geometrien zu einem Feature zusammengefasst werden. Ein Beispiel wäre eine Beobachtung für ein Land, das aber aus mehreren Polygonen bestehen kann (z.B. Festland und Inseln). Features können dann weitere Attribute (= Attributdaten) haben, z.B. eine ID, Name oder was auch immer man gemessen hat.

Rasterdaten bestehen aus einer Oberfläche von gleichgroßen Kacheln (= *Pixel*), die ein Gebiet abdecken. Meist sind Pixel viereckig, aber das ist keine Voraussetzung. Dabei hat jedes Pixel einen Wert (das kann auch ein fehlender Wert sein). Typische Beispiele für Rasterdaten sind Landnutzung oder Seehöhen.

In R kann sowohl mit Vektor- als auch mit Rasterdaten gearbeitet werden. Für Vektordaten bietet sich das Paket **sf** an und für Rasterdaten das Paket **raster**.

### 14.2 Koordinatenbezugssystem

Eine der Herausforderungen für räumliche Daten ist die eindeutige Verortung im Raum. Dazu braucht man ein *Koordinatenbezugssystem* (KBS). Einem KBS liegt ein mathematisches Modell der Erde zugrunde. Die Details zu KBS werden schnell relativ kompliziert und wir beschränken uns hier lediglich darauf, wie KBS verwendet werden können. Dazu müssen wir zwei Fälle unterscheiden: 1) einem Datensatz ein KBS zuweisen und 2) Transformation des KBSs eines Datensatzes in ein anderes KBS. Die technischen Details werden in den folgend Abschnitten besprochen. Für beide Aufgaben müssen wir auf ein KBS verweisen können, ein einfacher Ansatz dafür sind die sogenannten *EPSG-Codes*<sup>16</sup>.

<sup>16</sup>EPSG steht für European Petrol Survey Group

### 14.3 Vektordaten in R

Das Paket `sf` stellt Klassen zum Abbilden von Features zur Verfügung, die dann in einem `data.frame` als Liste gespeichert werden können. In der Regel erstellen wir Features nicht individuell, sondern lesen diese aus externen Datenquellen (z.B. ESRI Shapefile) ein. Zum besseren Verständnis, erstellen wir es einmal manuell. Wir haben die Koordinaten für drei Städte (Göttingen, Hannover und Berlin) als geografische Koordinaten vorliegen (EPSG = 4326).

```
library(sf)
goe <- st_point(x = c(9.9158, 51.5413))
han <- st_point(x = c(9.7320, 52.3759))
ber <- st_point(x = c(13.405, 52.5200))
```

Daraus können wir jetzt eine Geometriespalte für einen `data.frame` erstellen

```
geom <- st_sfc(list(goe, han, ber), crs = 4326)
```

Somit haben wir die Geometrie in der Variable `geom` gespeichert, aber noch keine dazugehörigen Attributdaten. Diese können wir jetzt in einem weiteren `data.frame` abspeichern.

```
attr <- data.frame(
  name = c("Goettingen", "Hannover", "Berlin"),
  bundesland = c("Niedersachsen", "Niedersachsen", "Berlin"),
  einwohner = c(119000, 532000, 3650000)
)
```

In einem letzten Schritt möchten wir jetzt die Geometrie (`geom`) und die Attributdaten (`attr`) zusammenführen.

```
staedte <- st_sf(attr, geom = geom)
staedte
```

```
## Simple feature collection with 3 features and 3 fields
## Geometry type: POINT
## Dimension: XY
## Bounding box: xmin: 9.732 ymin: 51.5413 xmax: 13.405 ymax: 52.52
## Geodetic CRS: WGS 84
##      name      bundesland einwohner      geom
## 1 Goettingen Niedersachsen   119000 POINT (9.9158 51.5413)
## 2  Hannover Niedersachsen   532000 POINT (9.732 52.3759)
## 3   Berlin      Berlin   3650000 POINT (13.405 52.52)
```

Wir können nun mit `staedte` genau so arbeiten wie mit jedem anderen `data.frame` und die Geometrien werden immer 'berücksichtigt'. Zusätzlich kann man eine Reihe von geometrischen Operationen durchführen.



Wenn ein `data.frame` Punkten hat, kann man dies relative einfach mit der Funktion `st_as_sf()` “räumlich” machen. Für das vorherige Beispiel würden wir zuerst einen `data.frame` mit allen Informationen (zur Geometrie und zu den Attributen erstellen).

```
dat <- data.frame(
  name = c("Goettingen", "Hannover", "Berlin"),
  bundesland = c("Niedersachsen", "Niedersachsen", "Berlin"),
  einwohner = c(119000, 532000, 3650000),
  x = c(9.9158, 9.7320, 13.405),
  y = c(51.5413, 52.3759, 52.5200)
)
```

Dann kann man mit der Funktion `st_as_sf()` weiter arbeiten:

```
staedte1 <- st_as_sf(dat, coords = c("x", "y"), crs = 4326)
```

## 14.4 Arbeiten mit Vektordaten

Es gibt sehr viele Funktionen, um mit räumlichen Daten zu arbeiten, von denen wir hier einige vorstellen.

```
# Zeigt das KBS an
st_crs(staedte)
```

```
## Coordinate Reference System:
##   User input: EPSG:4326
##   wkt:
##   GEOGCRS["WGS 84",
##     ENSEMBLE["World Geodetic System 1984 ensemble",
##       MEMBER["World Geodetic System 1984 (Transit)"],
##       MEMBER["World Geodetic System 1984 (G730)"],
##       MEMBER["World Geodetic System 1984 (G873)"],
##       MEMBER["World Geodetic System 1984 (G1150)"],
##       MEMBER["World Geodetic System 1984 (G1674)"],
##       MEMBER["World Geodetic System 1984 (G1762)"],
##       MEMBER["World Geodetic System 1984 (G2139)"],
##       ELLIPSOID["WGS 84",6378137,298.257223563,
##         LENGTHUNIT["metre",1]],
##       ENSEMBLEACCURACY[2.0]],
##     PRIMEM["Greenwich",0,
##       ANGLEUNIT["degree",0.0174532925199433]],
##     CS[ellipsoidal,2],
##     AXIS["geodetic latitude (Lat)",north,
##       ORDER[1],
```

```

1909 ##          ANGLEUNIT["degree",0.0174532925199433]],
1910 ##          AXIS["geodetic longitude (Lon)",east,
1911 ##              ORDER[2],
1912 ##          ANGLEUNIT["degree",0.0174532925199433]],
1913 ##  USAGE[
1914 ##      SCOPE["Horizontal component of 3D system."],
1915 ##      AREA["World."],
1916 ##      BBOX[-90,-180,90,180]],
1917 ##  ID["EPSG",4326]]

```

1918 Wenn wir jetzt zu einem anderen KBS (z.B. EPSG:3035, ein europäisches projiziertes KBS) umrechnen  
 1919 möchten, können wir das mit

```

s2 <- st_transform(staedte, 3035)
st_crs(s2)

```

```

1920 ## Coordinate Reference System:
1921 ##   User input: EPSG:3035
1922 ##   wkt:
1923 ## PROJCRS["ETRS89-extended / LAEA Europe",
1924 ##     BASEGEOGCRS["ETRS89",
1925 ##       ENSEMBLE["European Terrestrial Reference System 1989 ensemble",
1926 ##         MEMBER["European Terrestrial Reference Frame 1989"],
1927 ##         MEMBER["European Terrestrial Reference Frame 1990"],
1928 ##         MEMBER["European Terrestrial Reference Frame 1991"],
1929 ##         MEMBER["European Terrestrial Reference Frame 1992"],
1930 ##         MEMBER["European Terrestrial Reference Frame 1993"],
1931 ##         MEMBER["European Terrestrial Reference Frame 1994"],
1932 ##         MEMBER["European Terrestrial Reference Frame 1996"],
1933 ##         MEMBER["European Terrestrial Reference Frame 1997"],
1934 ##         MEMBER["European Terrestrial Reference Frame 2000"],
1935 ##         MEMBER["European Terrestrial Reference Frame 2005"],
1936 ##         MEMBER["European Terrestrial Reference Frame 2014"],
1937 ##       ELLIPSOID["GRS 1980",6378137,298.257222101,
1938 ##         LENGTHUNIT["metre",1]],
1939 ##       ENSEMBLEACCURACY[0.1]],
1940 ##     PRIMEM["Greenwich",0,
1941 ##       ANGLEUNIT["degree",0.0174532925199433]],
1942 ##     ID["EPSG",4258]],
1943 ##   CONVERSION["Europe Equal Area 2001",
1944 ##     METHOD["Lambert Azimuthal Equal Area",
1945 ##       ID["EPSG",9820]],
1946 ##     PARAMETER["Latitude of natural origin",52,
1947 ##       ANGLEUNIT["degree",0.0174532925199433],

```

```

1948 ##           ID["EPSG",8801]],
1949 ##           PARAMETER["Longitude of natural origin",10,
1950 ##             ANGLEUNIT["degree",0.0174532925199433],
1951 ##           ID["EPSG",8802]],
1952 ##           PARAMETER["False easting",4321000,
1953 ##             LENGTHUNIT["metre",1],
1954 ##           ID["EPSG",8806]],
1955 ##           PARAMETER["False northing",3210000,
1956 ##             LENGTHUNIT["metre",1],
1957 ##           ID["EPSG",8807]]],
1958 ##   CS[Cartesian,2],
1959 ##     AXIS["northing (Y)",north,
1960 ##       ORDER[1],
1961 ##       LENGTHUNIT["metre",1]],
1962 ##     AXIS["easting (X)",east,
1963 ##       ORDER[2],
1964 ##       LENGTHUNIT["metre",1]],
1965 ##   USAGE[
1966 ##     SCOPE["Statistical analysis."],
1967 ##     AREA["Europe - European Union (EU) countries and candidates. Europe - onshore and offshore: A"],
1968 ##     BBOX[24.6,-35.58,84.73,44.83]],
1969 ##   ID["EPSG",3035]]

```

1970 Die Funktion `st_buffer()` erlaubt es Features zu puffern, mit `st_distance()` kann die Distanz zwischen  
 1971 Features berechnet werden, mit `st_area()` kann die Fläche eines Features zu berechnen.

1972 Funktionen wie `st_intersection()`, `st_union()` und `st_difference()` erlauben es geometrische Opera-  
 1973 tionen zwischen unterschiedlichen Features zu berechnen. Für eine ausführliche Diskussion siehe auch hier:  
 1974 <https://geocompr.robinlovelace.net/geometric-operations.html>.

1975 Normalerweise lesen wir Daten von externen Datenquellen (z.B. ESRI Shapefiles). Das geht mit der Funktion  
 1976 `st_read()`.

## 1977 14.5 Rasterdaten in R

1978 Für Rasterdaten gibt es das R-Paket `raster`. Auch hier wollen wir uns wieder auf einige Grundfunktionali-  
 1979 täten konzentrieren. Diese umfassen das Einlesen, Zuschneiden, Rechnen und Abfragen von Rastern.

1980 Mit der Funktion `raster()` kann ein Raster in R eingelesen werden.

```

library(raster)
dem <- raster(here::here("data/dem_3035.tif"))

```

1981 `dem` steht für *Digital Elevation Model* und ist ein Raster mit den Seehöhen in Niedersachsen mit einer  
 1982 500-m-Auflösung. Wir können diese mit der Funktion `res()`<sup>17</sup> abfragen.


<sup>17</sup>kurz für *resolution* also Auflösung.

```
res(dem)
```

```
## [1] 500 500
```

Bzw. wir können den Raster auch plotten.

```
plot(dem)
```



1985

1986 Wenn wir den Raster `dem` auf ein Gebiet zuschneiden wollen (z.B. Göttingen), müssen wir drei Schritte  
1987 durchführen. Als erstes müssen wir ein Shapefile für Göttingen einlesen.


```
goe <- st_read(here::here("data/goettingen/stadt_goettingen.shp"))
```

1988 Dann müssen wir sicher stellen, dass sowohl der Raster `dem` als auch das `sf`-Objekt `goe` im selben KBS sind.  
1989 Es bietet es sich in der Regel an, das KBS des Vektors zu transformieren. Mit der Funktion `projectRaster()`  
1990 kann das KBS eines Raster transformiert werden.

```
goe <- st_transform(goe, 3035)
```

1991 Mit der Funktion `crop()` kann der Raster `dem` auf Göttingen zugeschnitten werden.


```
dem1 <- crop(dem, goe)
plot(dem1)
```



1992

1993 Der Raster hat jetzt die Größe einer Bounding-Box (BBX) von Göttingen (das ist ein Rechteck, das Göttingen  
1994 umfasst). Mit der Funktion `mask()` kann der Raster auf die genauen Grenzen des Vektors `goe` angepasst  
1995 werden.

```
dem2 <- mask(dem1, goe)
plot(dem2)
```



1996

1997 Wenn wir an bestimmten Punkten den Wert des Rasters abfragen wollen (z.B. an `cities`) von vorhin, dann

gibt es dafür die Funktion `extract`. Dann müssen wir erst sicherstellen, dass `staedte` und `dem` gleichen KBS zu grunde liegt. Dafür transformieren wir einfach `staedte` in das KBS von `dem`. Mit der Funktion `projection()` erhalten wir das KBS des Rasters.

```
s1 <- st_transform(staedte, 3035)
```

Wenn wir das KBS eines Objektes nicht kennen, können wir auch einfach das KBS übergeben. Der folgende Code-Block macht genau das Gleiche mit dem Vorteil, dass wir keinen EPSG-Code angeben müssen.

```
s1 <- st_transform(staedte, projection(dem))
```

Dann können wir für jede Stadt die Seehöhe abfragen:

```
raster::extract(dem, s1)
```

```
## [1] 149.18181 57.21486 NA
```

Mit `raster::extract()` rufen wir *eindeutig* die Funktion `extract()` aus dem Paket `raster` auf. Wir müssen das so machen, weil es im Paket `dplyr` auch eine Funktion `extract()` gibt, die wir hier nicht anwenden möchten, da sie einen Fehler verursachen würde.


Ein analoges Vorgehen ist auch für Linien und Polygone möglich.

Mit Rastern kann auch einfach gerechnet werden. Wir können z.B. die Seehöhe in Kilometern anstatt Metern berechnen:

```
dem_km <- dem / 1e3
```

Auch logische Operationen sind möglich, wenn wir alle Rasterzellen mit einer Seehöhe von mehr als 300 m in Göttingen suchen, dann geht das so:

```
dem3 <- dem2 > 300  
plot(dem3)
```



2013

2014 Wenn wir jetzt auf die Werter des Rasters `dem3` zugreifen wollen, geht das mit eckigen Klammern.

```
head(dem3[])
```

```
## [1] NA NA NA NA NA NA
```

2016 Das sind erst einmal viele NA-Werte für die ganzen Zellen, die außerhalb von Niedersachsen liegen. Aber wir  
 2017 können mit so einem Vektor ganz normal arbeiten und z.B. die Fläche des Landes Niedersachsen die eine  
 2018 Seehöhe von mehr als 500m Seehöhe hat ausrechnen.

```
h <- dem3[]
sum(h, na.rm = TRUE) / sum(!is.na(h))
```

```
## [1] 0.265713
```

2020

### 2021 *Aufgabe 41: Arbeiten mit Rastern*

2022

2023 Verwenden Sie den Raster `wald.tif`, der auf einer 10 m Auflösung den Waldanteil jeder Rasterzelle angibt<sup>18</sup>.  
 2024 Der EPSG-Code für das KBS von `wald.tif` ist 3035. Nehmen Sie an, dass wenn der Waldanteil in einer Raster  
 2025 größer als 50 % ist, dass die Rasterzelle als Wald klassifiziert werden kann. Wie viel Prozent des Göttinger  
 2026 Stadtgebietes sind Wald? Wie ändert sich dieser Wert, wenn sie 70 % anstatt 50 % als Schwellenwert für  
 2027 Wald annehmen?

<sup>18</sup>Die können hier <https://land.copernicus.eu/pan-european/high-resolution-layers/> für ganz Europa bezogen werden

**Aufgabe 42: Studiendesign**

Mit der Funktion `st_sample()` können Sie innerhalb oder entlang eines Features zufällige Punkte legen. Das Argument `n` steuert die Anzahl Punkte und das Argument `type` wie die Punkte angeordnet werden. Für `type` sind für uns die Werte `type = "random"` (komplett zufällig), `type = "regular"` (regelmäßiger Grid) und `type = "hexagonal"` von Bedeutung (ein hexagonaler Grid, d.h. ein sechseckiger Raster). Unglücklicherweise ist das Ergebnis von `st_sample()` erst eine Geometrie. Um daraus ein vollständiges `sf`-Objekt zu machen und problemlos weiter arbeiten zu können, müssen Sie noch einmal die Funktion `st_as_sf()` ausführen.

Stellen Sie sich vor, dass wir die tatsächliche Waldbedeckung des Göttinger Stadgebietes **nicht** kennen und wir eine Studie durchführen, um den Anteil des Göttinger Stadgebietes, der mit Wald bedeckt ist herauszufinden. Erstellen Sie dafür einige unterschiedliche Stichproben (diese können in der Anzahl und Anordnung variieren).

Berechnen Sie für jedes Stichprobendesign den Anteil an Wald und ein dazugehöriges Konfidenzintervall (dieses können Sie mit der Formel  $\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$  berechnen, wobei  $\hat{p}$  der geschätzte Waldanteil ist und  $n$  die Stichprobengröße). Nehmen Sie an, dass eine Rasterzelle Wald ist, sobald  $> 50\%$  der Rasterzelle mit Wald bedeckt ist.

**Aufgabe 43: Räumliche Daten**

Verwenden Sie den folgenden Datensatz:

```
set.seed(123)
df1 <- data.frame(
  x = runif(100, 0, 100),
  y = runif(100, 0, 100),
  kronendurchmesser = runif(100, 1, 15),
  art = sample(letters[1:4], 100, TRUE)
)
```

1. Erstellen Sie ein `sf`-Objekt aus `df1`.
2. Puffern Sie jeden Baum mit seinem Kronendurchmesser.
3. Berechnen Sie die Kronenfläche jedes Baumes. *Hinweis: Die Funktion `st_area()` könnte dafür hilfreich sein.*
4. Welcher Baum hat die größte Kronenfläche?
5. Finden Sie für jede Art, den Baum mit der größten Kronenfläche.



2055

---

**Aufgabe 44: Arbeiten mit räumlichen Daten**

---

2056

2057

- 2058 1. Lesen Sie das ESRI Shapefile `goettingen/stadt_goettingen.shp` ein.
- 2059 2. Wie viele Features befinden sich in dem Shapefile?
- 2060 3. Welches Koordinatenbezugssystem (KBS) hat das Shapefile?
- 2061 4. Transformieren Sie das Shapefile in das KBS 3035.
- 2062 5. Erstellen Sie eine neue Spalte **A** in der Sie die Fläche jeder Gemeinde/Stadt speichern.
- 2063 6. Welche Gemeinde/Stadt (Spalte **GEN**) ist am größten?
- 2064 7. Wählen Sie nun nur die Stadt Göttingen aus.

2065

---

**Aufgabe 45: Arbeiten mit räumlichen Daten 2**

---

2066

2067

- 2068 1. Lesen Sie erneut das ESRI Shapefile `goettingen/stadt_goettingen.shp` ein.
- 2069 2. Lösen Sie die Gemeindegrenzen auf (die Funktion `st_union()` könnte hier nützlich sein).
- 2070 3. Wie groß ist das resultierende Feature?

## 2071 15 FAQs (Oft gefragtes)

### 2072 15.1 Arbeiten mit Daten

#### 2073 15.1.1 Einlesen von Exceldateien

2074 Mit der Funktion `read_excel()` aus dem Paket `readxl` können Exceldateien direkt in R eingelesen werden.  
2075 Ein Export als csv-Datei aus Excel ist nicht notwendig.

## 16 Zusätzliche Aufgaben

### Aufgabe 46: Standardisierung

Unter Standardisierung (oder auch z-Transformation) versteht man die Transformation einer Variable, so dass sie den Mittelwert 0 und die Varianz 1 hat. Die Formel für die Standardisierung ist

$$x_s = \frac{x - \mu_x}{\sigma_x}$$

wobei  $x$  die Variable ist,  $\mu_x$  ist der Mittelwert von  $x$  und  $\sigma_x$  ist die Standardabweichung von  $x$ .

Standardisieren Sie folgenden Vektor:

```
h <- c(0, 2, 3, 1, 0, 8, 3.4, 9, 6.8, 2.1)
```

Und speichern Sie das Ergebnis in `h_s`. Vergewissern Sie sich, dass die Standardisierung geklappt hat und berechnen Sie den Mittelwert und Standardabweichung von `h_s`.

### Aufgabe 47: Arbeiten mit logischen Werten

Verwenden Sie nochmals den Vektor mit der Anzahl Rehe, die an unterschiedlichen Fotofallenstandorten fotografiert wurden.

```
anzahl_rehe <- c(132, 79, 129, 91, 138, 144, 55, 103, 139, 105, 96, 146, 95, 118, 1007)
```

Für wie viele Standort trifft die Aussage zu  $90 \leq x < 120$ , wobei  $x$  für die Anzahl Fotos an einem Standort steht.

### Aufgabe 48: Auswählen von Elementen in einem Vektor

Lesen Sie die Datei `bhd_1.txt` ein. Und bearbeiten Sie folgende Aufgaben mit dieser Datei:

- Finden Sie den mittleren BHD aller Eichen.
- Wie viele Beobachtungen haben Sie für Eichen, Fichten und Buchen?
- Finden Sie alle Bäume, die 10, 20, 21, 23, 30, 37, 78, 79, 90, 91, 92 Jahre alt sind.

---

**Aufgabe 49: Arbeiten mit Daten**


---

Wang et al. (2019) haben in einer Fotofallenstudie das Verhalten und die Habitatselektion von Ozeloten im brasilianischen Amazonas untersucht. Ziel dieser Übung ist es mit dem Datensatz etwas vertraut zu werden, wir werden noch keine ökologischen Analysen durchführen. Mehr zu dem Datensatz erfahren Sie [hier](#). Eine etwas angepasste Version des Datensatzes können Sie aus dem StudIP Ordner `daten` (die Datei heißt `ozelote.zip`) herunterladen. Speichern Sie die Datei in ihrem RStudio Projekt und entzippen Sie sie. Der Ordner enthält zwei Dateien, für diese Übung brauchen wir lediglich die Datei `ozelote_standorte.csv`, die für jeden Fotofallen Standort einige Kovariaten angibt.

Bearbeiten Sie folgende Aufgaben:

1. Lesen Sie die Datei `ozelote_standorte.csv` in R und speichern Sie das Ergebnis in eine Variable `standorte`.
2. Wie viele Fotofallenstandorte gab es in der Studie?
3. Welcher Standort ist am Höchsten gelegen? Die Spalte `seehoehe` enthält die mittlere Seehöhe.
4. Finden Sie alle Standorte, die in unmittelbarer Nähe zu Flüssen sind. Eine Distanz von  $< 5$  m kann als Schwellenwert angenommen werden. Die Spalte `dist_fluss` gibt die Distanz zu Flüssen an.
5. Der Datensatz besteht aus verschiedenen Kameras, die jeweils für einen Zeitraum von 12 Tagen in einer Region aufgestellt wurden (Spalte `Region`). Erstellen Sie einen Plot, der den Zusammenhang zwischen der Region und Seehöhe darstellt.

---

**Aufgabe 50: Base Plots**


---

Erstellen Sie die folgende Beispielabbildung Schritt für Schritt selbst über Low-Level Funktionen. Die Rohdaten finden Sie in den Dateien `abbBeispiel.R` und `ertragstafeldaten.csv`.

- Die Wachstumskurve der Region 1 (blau) lautet  $41.45752(1 - \exp(-0.02168x))^{1.61787}$
- Die Wachstumskurve der Region 2 (rot lautet)  $51.11203(1 - \exp(-0.009129x))^{1.202401}$

wobei  $x$  das Baumalter in Jahren angegeben ist. Die 3 schwarzen Linien sind auf der Ertragstafel abgelesen. Die Beschriftungen der 3 Ertragstafelkurven, sowie des Ausreißers, sind Zusatzaufgaben.

---

**Aufgabe 51: ggplot2 Aufgabe**


---

1. Laden Sie den Datensatz `daten/bhd_1.txt`

2. Erstellen Sie ein Streudiagramm. Bilden Sie dabei den BHD gegen das Alter ab, wobei dies als Subplot für jedes Affnahmegebiet dargestellt werden sollte.
3. Verwenden Sie für jede Baumart eine eigene Farbe.
4. Erstellen Sie für jede Baumart einen Boxplot des BHDs.
5. Teilen Sie die Boxplots aus 4) auf jeweils einen Subplot pro Aufnahmegebiet auf.

### Aufgabe 52: Anwendungsbeispiel kontrollierter Programmabläufe

- Öffnen Sie ein neues, leeres R Skript.
- Laden Sie die Datei “stichprobe.csv” in eine Variable.

```
stpr <- read.csv("data/stichprobe.csv", fileEncoding = "UTF-8")
```

- Filtern Sie den Data Frame so, dass er nur noch die Baumart “Eiche” enthält. Speichern Sie den gefilterten Data Frame in einer NEUEN Variable ab.
- Berechnen Sie die deskriptiven Statistiken `mean()`, `sd()`, `median()`, `min()` und `max()` des Kapitels “Deskriptive Statistik” für den BHD (des gefilterten Data Frames).
- Erstellen Sie ein Histogramm des BHD (ebenfalls mit dem gefilterten Data Frame), zeichnen Sie den arithmetischen Mittelwert als horizontale Linie in das Histogramm ein.
- Speichern Sie den R Code und kopieren Sie ihn in ein neues R Skript.
- Erstellen Sie nun eine Schleife, die alle Statistiken und auch die Abbildung für jede Baumart berechnet. Lassen Sie die Statistiken mit `print()` in die Konsole ausgeben.
- ZUSATZ: Exportieren Sie die Histogramme (bspw. als PDF). TIPP: Verwenden Sie `paste()` um sinnvolle Namen für die Dateien zu erstellen. Machen Sie sich selbst mit der Funktion vertraut.
- ZUSATZ: Sie wollen Fehlermeldungen vermeiden. Deshalb programmieren Sie eine bedingte Ausführung, um die gesamten statistischen Berechnungen und auch die Abbildung. Führen Sie Ihren gesamten Code nur unter der Bedingung aus, dass die Baumart “Ei”, “Bu”, “Fi”, “Kie” oder “Dou” ist. TIPP: Sie können den `%in%` Operator verwenden.

## 16.1 Arbeiten mit Daten

Verwenden Sie erneut die Datensatz von Wang et al. (2019) zu Ozeloten in Brasilien für die nachfolgenden Übungen.

2161

---

**Aufgabe 53: Datenzusammenfassen**

---

2162  
2163

- 2164 1. Laden Sie die Datei `ozelote_standorte.csv` in R und speichern Sie das Ergebnis in eine Variable  
2165 `standorte`.
- 2166 2. Berechnen Sie die Anzahl an Fotofallen für jede Region. Welche Region weißt die meisten Fotofallen  
2167 auf?
- 2168 3. In welcher Region ist die größte Variabilität der Seehöhe zu finden?
- 2169 4. In welchen Region beträgt der Anteil an Fotofallen, die  $< 5\text{m}$  vom nächsten Fluss entfernt sind,  
2170 mindestens 20%?

2171

---

**Aufgabe 54: Datenmanipulation 1**

---

2172  
2173

- 2174 1. Laden Sie nun zusätzlich die Datei `ozelote_fanghistorien.csv` und speichern Sie diese in die Variable  
2175 (`fh`). In diesem `data.frame` gibt es für jede Session eine Spalte (`V1` bis `V10`). Eine 1 bedeutet, dass  
2176 mindestens ein Ozelot fotografiert wurde und eine 0 bedeutet, dass kein Ozelot in diesem Zeitraum  
2177 fotografiert wurde. NA heißt, dass die Kamera nicht aktiv war.
- 2178 2. Wählen Sie nur das 3. Fangereignis (das ist die Spalte `V3`).
- 2179 3. Wie viele Kameras waren beim 3. Fangereignis aktiv?
- 2180 4. Vergleichen Sie anhand einer Abbildung, ob sich die Distanz zum Fluss (Spalte `dist_fluss`) zwischen  
2181 Standorten mit Fotos (`V3 == 1`) und Standorten ohne Fotos (`V3 == 0`) unterscheidet.

2182

---

**Aufgabe 55: Datenmanipulation 2 (etwas knifflig)**

---

2183  
2184

- 2185 1. Verwenden Sie erneut die Daten zu den Fotofallenstandorten und Fanghistorien der Ozelote.
- 2186 2. Finden Sie alle Fotofallenstandorte an denen  $\geq 3$  Ozelote fotografiert wurden?
- 2187 3. Gibt es einen Zusammenhang zwischen der Häufigkeit an Ozelotfotos (pro Fotofallenstandort) und der  
2188 Distanz zum nächsten Fluss (Spalte `dist_fluss`)? Eine Abbildung ist ausreichend.

## 17 Literatur

Ein guter Überblick über viele der angeschnittenen Themen gibt es in dem [R for data science](#), das online frei zugänglich ist.

McNamara, Amelia, and Nicholas J Horton. 2018. “Wrangling Categorical Data in r.” *The American Statistician* 72 (1): 97–104.

Wang, Bingxin, Daniel G. Rocha, Mark I. Abrahams, André P. Antunes, Hugo C. M. Costa, André Luis Sousa Gonçalves, Wilson Roberto Spironello, et al. 2019. “Habitat Use of the Ocelot (*Leopardus Pardalis*) in Brazilian Amazon.” *Ecology and Evolution* 9 (9): 5049–62. <https://doi.org/10.1002/ece3.5005>.

Wickham, Hadley. 2014. “Tidy Data.” *Journal of Statistical Software* 59 (10). <https://doi.org/10.18637/jss.v059.i10>.